

华中科技大学

XH-202603

作品编码: 601617

面向太空智算的多模态遥感大模型应用探索
技术报告

M³-RS: MoE-Mind Multimodal Remote Sensing

童轶	贺威铭	谌睿健	易若轩	吴玮拉
焦妍雪	严巨群	陈旭洋	周壮	秦嘉悦

2026 年 9 月

目录

第一章 概述	1
第二章 引言	2
2.1 背景、约束与核心矛盾	2
2.2 技术路线与总体思路	2
2.3 主要贡献	4
第三章 系统架构设计	5
3.1 总体架构	5
3.2 任务空间与分解原则	6
3.3 领域 Agent 与任务处理	7
3.4 架构优势	8
第四章 训练方案	9
4.1 训练方案综述	9
4.2 训练数据构造	10
4.3 基于 LoRA 的参数高效训练方法	11
4.3.1 LoRA 基本原理	11
4.3.2 M ³ -RS 分任务参数高效适配方法	12
4.3.3 多模态生成监督	12
4.4 VisualTaskPlanner 训练方案	13
4.4.1 训练目标	13
4.4.2 数据组成与规划字段标注	13
4.4.3 训练配置	14
4.5 面向 Agent 工作流的领域适配训练	14
4.5.1 面向 Agent 输入输出边界的工作流对齐微调	14
4.5.2 General VQA Agent 训练	15
4.5.3 Caption Agent 训练	16
4.5.4 Grounding Agent 训练	17
4.5.5 Change Agent 训练	18
第五章 面向单粒子翻转的模型权重容错与恢复方案	20
5.1 问题描述与设计目标	20
5.2 总体技术方案	20
5.3 单粒子翻转的软件故障注入方法	21

5.3.1	Bit Flip 故障模型	21
5.3.2	不同浮点位的差异化故障模拟	22
5.3.3	不同模型模块的故障注入	22
5.4	单粒子翻转影响评估与关键权重识别	23
5.4.1	脆弱性评价	23
5.4.2	结合遥感多任务进行影响评价	24
5.5	权重错误校验机制	24
5.5.1	模型文件级 SHA-256	24
5.5.2	运行时关键权重 Checksum	24
5.5.3	数值异常辅助检测	25
5.6	关键权重选择性保护与模型故障恢复	25
5.6.1	分级选择性保护	25
5.6.2	Golden Checkpoint 恢复	26
5.6.3	故障恢复后的重推理	26
5.7	面向卫星平台的轻量化设计	27
5.8	故障容错实验设计	27
5.9	方案创新点	28
5.10	总结	29
第六章	测试方案与结果	30
6.1	评测设置	30
6.2	综合评测结果	30
6.3	VRSBench 评测结果与分析	31
6.4	XLRS-Bench 评测结果与分析	32
6.5	MME-RealWorld-RS 评测结果与分析	32
6.6	LEVIR-CC 评测结果与分析	33
6.7	分层对照分析	33
6.7.1	视觉辅助路径对照	33
6.7.2	跨数据集 VQA 迁移对照	34
6.8	推理效率与资源开销	35
6.9	失败案例与能力不足	36
6.10	本章小结	36
第七章	未来工作	37
7.1	国产化硬件平台适配	37
7.2	全链路量化与推理加速	38
第八章	结论	39
附录 A	作品交付与复现说明	43

- A.1 交付材料组成 43
- A.2 代码与运行入口 43
- A.3 大容量文件下载信息 43
- A.4 最小复现流程 43
- 附录 B 模型与 Adapter 资产说明 44
- 附录 C DeepSeek 辅助 Planner 监督字段标注方法 45
 - C.1 标注目的与字段范围 45
 - C.2 仅问题文本的 Teacher 调用 45
 - C.3 固定 Prompt 与结构化输出 45
 - C.4 确定性校验与异常隔离 45
- 附录 D 基于 Qwen3.5-Flash 的外部语义评测方法 47
 - D.1 评测定位与适用范围 47
 - D.2 输入与任务专用评分准则 47
 - D.3 三轮离散评分与百分制映射 47
 - D.4 聚合、失败处理与复现配置 48
- 附录 E VisualTaskPlan v5 格式 49
 - E.1 总体结构 49
 - E.2 字段定义 49
 - E.3 RegionRequest 格式 50
 - E.4 字段联动约束 50

第一章 概述

面向太空智算环境下遥感影像幅面大、目标尺度差异显著以及计算与存储资源受限等问题，本项目研发了多模态遥感智能体系统 M^3 -RS (MoE-Mind Multimodal Remote Sensing)。系统面向目标检测与定位、场景分类、变化检测、目标计数和遥感图像描述五类核心能力，将不同任务对全局语义、局部几何、像素级信息和双时相证据的需求纳入统一框架，在有限算力条件下实现多类遥感任务的一体化理解与处理。

M^3 -RS 采用任务—证据联合规划与领域智能体协同的总体架构。视觉任务规划器 (VisualTaskPlanner) 根据原始问题与有序图像预览，在一次规划中确定规范任务、任务语义及可选的局部视觉证据范围，并据此将任务交由相应的领域智能体处理。各领域智能体依据任务特点，综合全局场景信息、任务相关局部证据和按需调用的视觉专家完成推理。系统以 Qwen3.5-9B 为共享多模态基座，通过面向不同任务的低秩适配 (Low-Rank Adaptation, LoRA) 形成规划、问答、描述、定位和变化理解等专门能力，从而以统一基座支持差异显著的遥感任务，并降低多任务扩展带来的模型冗余。此外，面向星载长期运行中的单粒子翻转风险，系统设计了基于权重校验、选择性保护和局部恢复的轻量化容错方案。

项目在 VRSBench、XLRS-Bench、LEVIR-CC、MME-RealWorld-RS 等公开遥感数据集上开展了多任务训练与系统评测，覆盖十个内部规范任务以及目标定位、视觉问答、图像描述、目标计数和变化理解等处理场景。其中，VRSBench 目标定位任务取得 71.92% 的 Acc@0.5 和 61.70% 的 Mean IoU；未参与对应训练的 XLRS-Bench VQA 在 zero-shot 条件下取得 58.99% 的 Exact Match，与 VRSBench VQA 的 58.83% 处于相近量级。对 VRSBench VQA 的观察性分组结果显示，启用视觉辅助的样本在目标位置、目标形状和推理类问题上的 Exact Match 分别高出 8.89、5.75 和 8.69 个百分点，表明按任务需求组织目标级视觉证据与系统设计目标一致。 M^3 -RS 通过任务分解、证据协同和模型复用，在统一框架内协调不同遥感任务的输入特征、证据形式与输出约束，验证了以共享多模态基座和领域智能体承接多类遥感任务的可行性，可为受限算力平台上的多模态遥感应用提供技术支撑。

关键词：多模态遥感；太空智算；任务—证据联合规划；领域智能体；视觉语言模型；低秩适配；资源受限推理；模型权重容错

第二章 引言

2.1 背景、约束与核心矛盾

遥感智能处理需要同时面对场景分类、目标定位、变化理解、目标计数和图像描述等多类任务。这些任务不仅输出形式不同，对视觉证据的需求也存在明显差异：场景分类依赖全局语义，目标定位依赖局部几何，目标计数需要识别密集小目标，变化理解需要联合分析双时相证据，图像描述则要求在整体场景与局部细节之间保持一致。与此同时，遥感影像通常幅面较大、目标尺度跨度显著，直接缩放容易丢失车辆、船舶等小目标细节，固定切块又会引入大量与当前问题无关的视觉内容。因而，遥感多任务处理不能只追求统一输入输出，还必须针对不同任务组织相应的视觉证据与推理过程。

在算力和存储资源受限的星载应用设想中，依靠不断扩大模型规模来覆盖上述能力并不是当然可行的路线。大型通用多模态模型能够以统一接口处理多种视觉语言任务，但其权重规模、显存占用和推理开销会增加部署负担；如果仅将通用模型缩小，又可能削弱其对遥感专业语义、密集小目标、局部几何和双时相变化等问题的处理能力。因此，本项目面对的核心矛盾不是简单选择一个更大或更小的模型，而是**如何在不为每类任务分别部署完整大型模型的前提下，组织有限的模型能力，使一个统一系统能够承接多类异构遥感任务。**

本项目据此将研究问题界定为：在面向星载应用的有限算力约束下，如何通过任务组织、证据协同与模型复用，在不部署多个大型模型的前提下，以统一系统承接赛事要求的五类异构遥感任务。

2.2 技术路线与总体思路

现有遥感视觉语言研究主要沿两类路线扩展任务能力。一类以 GeoChat[1]、Ring-MoGPT[2] 等为代表，通过统一视觉语言模型承接视觉问答、场景理解、图像描述、目标定位或变化描述等任务，其能力覆盖主要依赖统一模型参数容量、训练数据与任务适配；另一类以 RS-Agent[3] 等为代表，使用语言模型理解用户意图并编排遥感专业工具，重点提升复杂任务的自动规划能力与工具扩展能力。上述路线推动了遥感多任务理解与自动化处理，但面向星载场景预设的有限算力约束时，仍需进一步回答一个系统性问题：当不能为不同任务分别部署完整模型，也不能单纯依靠扩大通用模型规模获得能力时，如何组织共享模型、任务专长与专业视觉工具，使异构任务在统一系统中得到处理。

这一问题的难点在于，五类遥感任务所需的视觉证据和输出契约并不一致。将全部能力压入同一推理路径，会要求共享模型同时承担全局语义理解、局部几何分析、密集目标辨识和双时相变化判断；为每项任务配置独立模型或持续叠加专业工具，又会增加权重、显存和运行管理负担。因此，有限算力条件下的多任务统一不能只依赖模型能力

的横向扩展，还需要在系统层面对任务边界、模型复用方式和专家调用条件进行协同设计。M³-RS 据此将多任务能力覆盖问题转化为资源约束下的能力组织问题。

为此，M³-RS 以任务组织、证据协同与模型复用为总体思路。任务组织方面，系统将赛事要求的五类核心能力细分为十个边界明确的规范任务，使每次推理面对相对确定的证据需求和输出契约。证据协同方面，系统根据任务需要按需调用目标检测、语义分割和变化感知等视觉专家，由专家提供候选区域或辅助证据，再由领域 Agent 按照任务约束完成证据融合与最终回答。模型复用方面，规划、问答、描述、定位和变化理解等模块共享 Qwen3.5-9B 多模态基座，并通过任务专用 LoRA 形成不同能力，避免为每类任务分别维护完整基础权重。




图 2-1 M³-RS 五类遥感能力与领域 Agent 协同示意

在具体任务流程中，系统首先将原始问题与一幅或多幅有序遥感图像整理为统一输入，并由 VisualTaskPlanner 进行一次任务—证据联合规划。Planner 根据问题语义和图像预览确定样本所属的规范任务，同时给出与任务执行相关的物体类别、计数目标以及可选的局部关注区域。规划结果通过 Schema 和能力约束校验后，系统据此生成后续 Agent 所需的全局图像、局部视图和任务上下文，再由确定性的 TaskRouter 将任务映射至对应领域 Agent。

领域 Agent 接收规划结果和视觉输入后，按照任务特征组织推理链路：能够由整幅图像直接回答的任务进入共享多模态基座；需要局部几何、目标分布或双时相差异信息的任务，则按需调用目标检测、语义分割专家，将其输出转换为辅助证据后与原始图像共同提交给任务专用模型。Agent 生成符合统一结果契约的答案后，系统保存预测结果、执行状态和证据记录，并依据实际任务计算相应的确定性指标；可选的外部语义 Judge 作为独立审计信号附加记录，最终由报告模块汇总已经持久化的结果。由此形成“任务识别 → 任务路由 → 代理执行”的完整处理流程。

2.3 主要贡献

- 提出面向有限算力约束的**多任务能力组织架构**。系统通过任务组织、证据协同与模型复用协调不同遥感任务的输入特征、证据形式和输出契约，在不为每类任务分别部署完整大型模型的前提下，以统一入口承接多类异构遥感任务。
- 建立共享多模态基座上的**任务专门化机制**。VisualTaskPlanner、General VQA、Caption、Grounding 和 Change 等模块共享 Qwen3.5-9B 基础权重，并挂载相互独立的适配器承载任务专长，以降低多任务扩展造成的基础模型冗余。
- 建立视觉语言模型与专业视觉专家协同的**证据驱动执行框架**。目标检测、语义分割和变化感知等模块按需提供候选或辅助证据，领域 Agent 负责按照任务契约进行约束、融合与最终回答，避免将单一专家输出直接作为所有任务的最终裁决。
- 在统一系统中实现并验证赛事要求的目标检测与定位、场景分类、变化检测、目标计数和遥感图像描述五类核心能力，同时建立从样本、事件、预测、评测到只读报告的可恢复工件链，为系统运行、结果复查和后续补评测提供工程保障。

第三章 系统架构设计

3.1 总体架构

遥感图像理解与自然图像理解存在两类结构性差异。其一是观测尺度：原始影像幅宽大，目标尺度跨度从整幅场景到单个车辆、船舶、跑道附属物，直接缩放会丢失小目标细节，而固定全图切块又会引入大量无关视觉内容。其二是任务形态：定位需要局部几何并输出坐标，计数需要对密集小目标做精确估计并输出数值，变化检测需要对双时相图像做对齐与差分，描述需要兼顾整体语义与局部细节并输出自由文本——这些任务对“系统应该看到什么”与“系统应该输出什么”的要求彼此不同。

在算力受限、显存有限的部署条件下，一个自然的想法是用一个更大的通用视觉语言模型同时覆盖所有任务。但这一思路面临双重矛盾：一方面，通用模型的单一输出模式难以同时满足坐标、掩膜、数量、双时相差异、自由文本这些结构差异极大的输出契约；另一方面，模型规模本身在受限平台上难以承受。因此，M³-RS 不以模型规模换取能力，而改以分而专之的模块化范式换取多任务覆盖：把遥感任务分解为若干窄任务，每个窄任务交给一个专门设计的领域 Agent 按该任务所需的证据与输出契约处理；所有 Agent 共享同一个小的视觉语言模型基座，仅通过按任务切换的轻量 LoRA 适配器实现角色专才化。目标检测、语义分割、变化感知等视觉专家作为轻量的辅助证据来源按需调用，不构成多个并行的大模型。

基于上述设计理念，系统采用“**任务识别** → **任务路由** → **代理执行**”的三阶段流水线架构。具体而言，视觉任务规划器（VisualTaskPlanner）首先对输入查询同时进行任务类别判定与局部区域感知需求判别；经确认的任务类型由任务路由器（TaskRouter）唯一映射至对应的领域代理；该代理依据任务需求，整合全局上下文特征、可选的局部细粒度特征以及视觉专家模块的辅助证据，进行推理并生成作答。




图 3-1 M³-RS 多模态遥感智能体系统架构

3.2 任务空间与分解原则

任务集合由遥感领域实际待解答问题中归纳。这些问题可归纳为模型五类核心能力：目标检测与定位、场景分类、变化检测、目标计数及遥感图像描述。五类任务虽在形式上呈并列关系，但其所需的证据模态存在本质差异：目标检测依赖目标的局部几何特征，输出坐标表征；目标计数依赖对密集小目标的精确估计，输出数值；场景分类依赖整幅场景的全局语义，输出离散类别标签；变化检测依赖双时相图像的对齐与差分，输出变化描述；图像描述则需兼顾整体语义与局部细节，输出自由文本。

核心挑战在于，上述证据模态相互间缺乏兼容性。若以单一模型同时适配坐标、数值、类别、差异描述与自由文本等多类输出，实质上要求模型在每次推理中隐式地自我约束输出结构，而生成式模型恰恰难以可靠地保证这种格式一致性。为此，本项目不寻求单一模型覆盖全局，而是将证据需求相近的任务聚类为十个窄域任务本文定义为规范任务，CanonicalTasks)，再将各窄域任务按其处理范式映射至五个领域代理（Agents）分别承担。表 3-1 给出任务聚类与代理分配的完整对应关系。

表 3-1 任务聚类与代理分配对应关系

赛题核心能力	内部任务 (canonical task)	承担 Agent
目标检测与定位	grounding	GroundingAgent
变化检测	change_caption、change_qa	ChangeAgent
目标计数	counting、fine_grained_counting	CountingAgent
遥感图像描述	caption	CaptionAgent
通用问答、空间推理、场景分类	general_vqa、spatial_relation、multiple_choice_vqa、scene_classification	GeneralVQAAgent

这一映射是静态的，无法判定一条样本在运行时属于哪个任务：同一类图像、相近的问题文本，可能因内容不同而需要不同证据。例如询问“图中左上角有几辆车”时，小图仅需整图计数，大图则需先定位区域再计数。因此，系统在运行时需要对每条样本执行一次任务—证据联合规划，由视觉任务规划器（VisualTaskPlanner）同时判定任务类别与局部区域感知需求，前者决定派发至哪个代理、按何种契约输出，后者决定是否补充关键区域。

3.3 领域 Agent 与任务处理

五个领域代理共用同一套运行时，差别集中在任务内部的证据组织方式上。每个代理消费上游的 VisualTaskPlanner 的产物，来选择自己的工作流。下面依次考察五个代理各自的工作流。

CountingAgent：该 Agent 的工作流分为两个阶段，规划阶段把 VisualTaskPlanner 给出的计数目标解析为规范的类别集合，依据类别能力决定采用哪些后端及其回退顺序；执行阶段则实际调用各后端，切片拼接与几何去重。结论的裁决直接由证据决定：最终数值等于已接受的证据，当全部专家不可用时则回退为语言模型计数路径。证据类型按目标特性选择：形态清晰、适合定位的目标（如车辆、船舶）通过 YOLO，密集或区域性目标则通过语义分割的方式进行点计数。通过 VisualTaskPlanner 区分这两种目标。

ChangeAgent：该 Agent 将双时相变化检测划分为输入校验、证据一致化、候选生成、语义判定和结果复核五个环节。系统首先检查 T1、T2 的时相角色、图像有效性及配对关系。随后依次进行几何配准和辐射一致化，分别减弱空间错位以及亮度、色彩和成像条件差异带来的干扰，并通过质量门控限定有效分析区域。在此基础上，变化感知模块综合像素差异、特征差异和语义差异，根据各类证据的可靠性生成并融合候选变化区域。系统再将原始 T1/T2 图像、一致化对比结果和候选区域按固定顺序组织为结构化证据，交由语言模型判断是否发生变化、变化位置及其地物语义。原始双时相图像承担最终语义确认，一致化图像、差异图和候选掩膜用于提示模型关注潜在变化区域。初步结论生成后，确定性规则检查结论与候选强度、双时相证据和空间位置的一致性；证据一致时直接输出，出现冲突时对相关候选区域进行一次受限复核。针对常规流程可能遗

漏的建筑新增与拆除，系统还设置结构变化补充通道，对少量高价值候选进行专项确认。该流程兼顾变化发现的敏感性与语义判断的可靠性，可减少几何错位、辐射差异、季节变化、阴影和临时目标引起的误报。

GroundingAgent: 该 Agent 将目标定位划分为区域分析、候选生成、语义筛选和坐标回映四个环节。VisualTaskPlanner 首先判断是否需要局部视觉辅助。需要辅助时，系统按照规划区域提取局部图像，由检测模块生成带有类别和局部坐标的候选目标；随后将局部图像、候选类别和候选位置组织为结构化证据，交由语言模型结合问题中的目标类别、方位、大小及空间关系完成筛选。模型输出局部区域内的目标选择结果，确定性几何模块再将局部坐标转换为整幅图像上的统一坐标，并检查坐标范围和输出格式。无需局部辅助时，Agent 直接基于整幅图像执行定位。最终结果采用统一的归一化坐标表示，保证不同图像尺寸下的定位结果具有一致的格式和尺度。

GeneralVQAAgent: 该 Agent 统一处理通用视觉问答、场景分类、空间关系判断和多项选择问答。VisualTaskPlanner 首先判断当前问题能否通过整幅图像直接回答。对于全局场景理解或证据需求较弱的问题，Agent 将原始图像和问题直接交由语言模型完成推理。对于需要局部目标信息的问题，系统依据规划区域调用检测和分割模块，提取目标位置、类别和区域分布等辅助信息；检测结果被渲染为标注图，分割结果被转换为纯色掩膜，并与未标注的局部图像共同组成视觉证据。所有证据按照固定顺序和角色送入一次语言模型调用，使模型能够结合全局语境、局部细节和问题要求生成答案。

CaptionAgent: 该 Agent 采用面向遥感影像描述的直接生成流程。系统按照样本中规定的顺序读取图像，并将图像、任务类型和原始描述要求共同送入语言模型。任务专用提示词引导模型从场景类型、主要地物和空间布局三个方面提取关键信息，生成简洁、完整且符合事实的自然语言描述。

五个代理的处理方式各不相同，但最终都收敛为同一个视觉语言模型上的有限次数调用。任务差异由提示词、证据组织与确定性逻辑承载，这使”共享一个基座、按任务切换 LoRA”成为可行方案。

3.4 架构优势

我们认为在有限算力条件下，系统能力的提升主要依靠任务组织、证据协同与模型复用。针对遥感任务在输入形式、证据需求和输出结构上的差异，本项目通过任务分解建立清晰的处理边界，通过证据协同提升复杂遥感信息的利用效率，并通过共享基座和轻量适配降低多任务扩展成本。三者共同构成面向有限算力环境的多模态遥感智能体架构，使多类任务能够在统一框架下获得可扩展、可验证和可复现的处理能力。

第四章 训练方案

4.1 训练方案综述

Qwen3.5-9B[4] 具备通用的视觉理解与文本生成能力，但单一通用模型难以充分满足多类遥感任务的性能要求。遥感影像具有俯视成像、目标尺度跨度大、地物分布密集等特点；场景理解、视觉问答、目标定位、变化理解和图像描述虽然最终均以文本形式返回结果，但其视觉关注对象、领域语义和推理目标并不相同。为增强模型在不同遥感任务中的专门能力，M³-RS 需要在通用多模态基座上开展任务适配训练。

除领域任务本身外，M³-RS 还要求模型学习项目 workflow 定义的任务规划能力。VisualTaskPlanner 需要根据图像和原始问题确定规范任务类型（canonical task）、视觉辅助需求及相关任务语义。这些能力并非通用视觉问答模型的原生训练目标，因此需要构造专门的 Planner 监督数据并训练独立 Adapter。

针对不同模块的能力需求，项目分别制定相应的模型训练与权重准备方案。我们分别训练 VisualTaskPlanner、General VQA、Caption、Grounding 和 Change Adapter。各 Adapter 使用本任务数据独立优化，从而在只维护一份基础权重的前提下形成可切换的任务专长。目标检测专家 YOLO OBB 单独训练；语义分割模块直接采用经过类别映射核验的开源 SegFormer 权重，不在本项目中进行再训练。




图 4-1 M³-RS 总体训练路线

图 4-1 表示本章的训练对象及资产关系，箭头不表示所有模型必须依次串行训练。Planner Adapter 与各领域 Agent Adapter 共享 Qwen3.5-9B 基座，YOLO OBB 作为独立视觉专家训练，SegFormer 则直接使用开源权重。

4.2 训练数据构造

比赛方案提供的四个数据集 VRSBench[6]、XLRS-Bench[7]、MME-RealWorld[8] 和 LEVIR-CC[9] 的原始标注格式并不一致。项目首先从原始标注中提取图像、问题、任务信息和目标答案，再按照对应模块的实际输入输出方式转换为多模态监督记录。每条记录包含有序图像、输入问题、模块所需的任务上下文以及期望生成的目标。此外，我们引入 SuperRS-VQA[10] 和 LRS-VQA[11] 两个数据集作为补充训练数据，以进一步丰富训练样本的任务类型和场景覆盖范围；训练数据中涉及的 DOTA 数据集定义见文献 [12]。

在完成不同来源数据的统一整理后，还需根据具体训练对象分别构造监督目标。VisualTaskPlanner 与领域 Agent 的监督目标不同。Planner 以 VisualTaskPlan v5 作为目标文本，学习任务类型、视觉辅助需求及相关规划字段；领域 Agent 则以对应的 AgentResult 作为目标，学习在既定 Agent 工作流中完成任务。二者均可归结为多模态上下文输入—目标文本生成的监督学习，但训练样本所表达的系统职责不同。

数据转换仅针对任务需要保留必要的特殊处理：VQA 数据将通用视觉问答、场景分类、空间关系和多项选择问答整理到 General VQA Agent 的统一训练边界；Caption 数据联合使用 VRSBench 和 XLRS，并统一模型接收的问题表达；Grounding 数据保留目标语义与位置之间的对应关系；Change 数据固定 T1、T2 双时相图像的输入顺序，并分别构造变化描述与变化问答监督。涉及一幅图像对应多个问题或一个图像对生成多条 episode 的数据，按照唯一图像或双时相图像对划分训练集与验证集，避免同一视觉内容跨 split 出现。

表 4-1 各模块训练数据构成

训练模块	数据来源	训练视觉样本	验证视觉样本	训练监督记录	验证监督记录	监督目标
VisualTaskPlanner	DOTA、HRSCD、LEVIR-CC、LRS、MiniFrance、VRSBench、XLRs 等	2,680	319	6,921	831	VisualTaskPlan v5
General VQA Agent	VRSBench、SuperRS-VQA (含 DOTA、HRSCD、MiniFrance 等)、LRS-VQA(-Supplement)	2,680	269	8,849	922	VQA AgentResult
Caption Agent	VRSBench、XLRs-Bench	1,570	141	1,570	141	Caption AgentResult
Grounding Agent	VRSBench、XLRs-Bench	1,076	120	1,076	120	Grounding AgentResult
Change Agent	LEVIR 相关数据	6,465 对	1,242 对	102,758 episodes	6,198 episodes	Change AgentResult

注：视觉样本表示去重后的单幅图像或双时相图像对；监督记录表示实际进入训练或验证过程的多模态记录。同一视觉样本可以产生多条监督记录，故两列数值可以不同：VisualTaskPlanner 与 General VQA Agent 多为“一图多问”，其中 Planner 训练集包含 1,881 幅单图与 799 个双时相图像对（验证集为 219 幅单图与 100 个图像对）；General VQA 的视觉样本由 VRSBench 2,329 幅、LRS-VQA(-Supplement) 314 幅、DOTA 13 幅、HRSCD 13 幅与 MiniFrance 11 幅图像构成（验证集合计 269 幅）；Change Agent 则是一个图像对派生多条变化描述或变化问答记录。Caption 与 Grounding 每份视觉样本恰好对应一条监督记录，故两列数值一致。General VQA Agent 的源文件合计 8,851 条记录，其中 2 条在数据准备阶段被排除，实际进入训练的监督记录为 8,849 条。

4.3 基于 LoRA 的参数高效训练方法

4.3.1 LoRA 基本原理

以下公式与参数量分析沿用 LoRA 的标准定义 [5]。

对于预训练模型中的线性变换：

$$y = W_0 x, \quad (4.1)$$

其中，预训练权重矩阵的维度为：

$$W_0 \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}. \quad (4.2)$$

传统全参数微调直接更新预训练权重；LoRA 则冻结原始权重，并使用两个低秩矩阵表示任务适配产生的权重增量：

$$\Delta W = \frac{\alpha}{r} B A. \quad (4.3)$$

因此，加入 LoRA 后的前向计算为：

$$y = \left(W_0 + \frac{\alpha}{r} BA \right) x. \quad (4.4)$$

两个低秩矩阵的维度分别为：

$$A \in \mathbb{R}^{r \times d_{in}}, \quad B \in \mathbb{R}^{d_{out} \times r}, \quad (4.5)$$

其中， r 为 LoRA 秩， α 为缩放系数。训练过程中预训练权重保持冻结，只更新矩阵 A 和 B 。原线性层的参数数量为：

$$d_{out}d_{in}, \quad (4.6)$$

LoRA 新增的可训练参数数量为：

$$r(d_{in} + d_{out}). \quad (4.7)$$

当 r 远小于模型隐层维度时，需要更新和保存的任务参数显著减少。LoRA 的设计假设是，特定任务所需的权重变化可以由低秩矩阵近似表示。训练完成后，低秩增量既可以作为独立适配器（Adapter）与基础模型共同加载，也可以按交付需求合并到基础权重中。在本项目中，我们将适配器挂载在基础模型之上。

4.3.2 M³-RS 分任务参数高效适配方法

M³-RS 中所有使用视觉语言模型的模块均共享 Qwen3.5-9B 基础权重。项目不为每项任务复制并微调整套模型，而是在同一基座上分别挂载 VisualTaskPlanner、General VQA、Caption、Grounding 和 Change LoRA。不同 Adapter 由各自任务数据独立优化，并在运行时根据当前模块加载。该方式使基础权重只需维护一份，任务相关能力则由独立 Adapter 承载，便于不同任务分别训练、更新和部署。

各 Adapter 主要作用于 Qwen3.5 语言模型的注意力投影层和前馈网络投影层。训练时冻结语言模型基础参数和视觉编码器，embedding 与 lm_head 默认不参与更新，优化器只接收训练方案批准的 LoRA 参数。

4.3.3 多模态生成监督

各模块均采用多模态自回归生成方式训练。图像、系统提示、问题和任务上下文构成输入，模型按照 token 顺序生成目标文本，并在目标输出对应的 token 范围内计算交叉熵损失：

$$L = - \sum_{t \in T_{\text{target}}} \log p_{\theta}(y_t | y_{<t}, I, q), \quad (4.8)$$

其中， I 表示一个或多个有序图像， q 表示问题及任务上下文， y_t 表示目标输出的第 t 个 token， T_{target} 表示实际参与损失计算的目标 token 集合， θ 表示对应 Adapter 的可训练参数。不同模块的目标内容有所差异：Planner 生成结构化任务计划，VQA 生成问

题答案，Caption 生成遥感图像描述，Grounding 生成目标定位结果，Change 生成变化描述或变化问答结果。

4.4 VisualTaskPlanner 训练方案

4.4.1 训练目标

VisualTaskPlanner 负责根据有序图像预览和原始问题生成后续 Agent 执行所需的任务计划。该计划确定样本所属的 canonical task，并进一步给出是否需要视觉辅助、相关物体类别、计数目标以及可选关注区域。Planner 给出的关注区域用于提示后续模块关注可能包含关键证据的局部区域，其作用是缩小视觉搜索范围。因此，ROI 只要求覆盖回答问题所需的主要证据区域，不将目标边界级定位精度作为训练目标。Planner 的输出决定后续任务路由和视觉证据组织，因此需要通过专门的监督数据学习项目 workflow 定义的规划能力。VisualTaskPlan v5 的完整字段格式与约束见附录 E。

4.4.2 数据组成与规划字段标注

Planner 训练数据共包含 7,752 条监督记录，其中训练集 6,921 条、验证集 831 条，覆盖系统定义的十个 canonical task。数据包括单图问答、描述、定位和计数任务，也包括双时相变化描述与变化问答任务。具体任务分布见表 4-2。

表 4-2 VisualTaskPlanner 任务分布

canonical task	训练	验证
caption	1,074	130
change_caption	800	100
change_qa	800	100
counting	307	35
fine_grained_counting	800	100
general_vqa	1,011	127
grounding	1,340	160
multiple_choice_vqa	588	54
scene_classification	180	24
spatial_relation	21	1
合计	6,921	831

原始公开数据集没有直接提供 Planner 所需的完整规划字段。项目使用 DeepSeek API 根据样本问题直接标注 task、needs_visual_assistance、object_categories 和 count_target，并结合规则校验和人工抽查完成质量控制；对于需要局部视觉辅助的样本，region_request.image_index 和 region_request.roi_xyxy 由人工结合图像与问题标注。DeepSeek 辅助标注、ROI 人工标注及质量控制方法见附录 C，VisualTaskPlan v5 字段格式与约束见附录 E。

4.4.3 训练配置

VisualTaskPlanner 使用 Qwen3.5-9B 作为基座，通过语言模型 LoRA 学习 VisualTaskPlan v5。训练配置见表 4-3。

表 4-3 VisualTaskPlanner 主要训练配置

配置项	设置
基础模型	Qwen3.5-9B
微调方式	语言模型 LoRA
LoRA rank	32
LoRA alpha	64
LoRA dropout	0.05
LoRA 目标层	248 个
视觉编码器	冻结
语言模型基础参数	冻结
embedding 与 lm_head	冻结
监督方式	自回归文本生成

VisualTaskPlan v5 中的 task、物体类别、计数目标和 ROI 坐标均被序列化为结构化文本，并通过自回归语言模型损失统一学习。

4.5 面向 Agent 工作流的领域适配训练

4.5.1 面向 Agent 输入输出边界的工作流对齐微调

传统多模态监督微调通常由训练脚本直接将图像、问题和答案拼接成模型输入输出对。这种方式只约束模型层面的问答行为，训练输入不一定与 Agent 正式运行时使用的提示、视觉视图和专家证据一致。**M³-RS 采用面向 Agent 输入输出边界的工作流对齐微调**：训练样本首先按照系统运行契约构造成 Agent 输入，再由对应 Agent 执行视觉视图选择、提示组织和可选专家证据调用。训练程序截获 Agent 最终提交给 Qwen 的真实多模态请求，并以期望的 AgentResult 作为监督目标更新对应 Adapter。

将第 k 个 Agent 的工作流记为 $\mathcal{A}_k$ 。对于任务样本 s 、Planner 结果 p 和可用视觉专家 E ，Agent 生成 Qwen 实际接收的多模态请求：

$$z_k = \mathcal{A}_k(s, p, E), \quad (4.9)$$

z_k 可以包含系统提示、原始问题、全局图像、Planner 选定的局部视图以及检测或分割证据。以期望的 Agent 公共输出 y_k 作为监督目标，第 k 个任务 Adapter 的优化目标为：

$$L_k = - \sum_{t \in T_k} \log p_{\theta_k}(y_{k,t} \mid y_{k,<t}, z_k), \quad (4.10)$$

其中， k 表示 VQA、Caption、Grounding 或 Change Agent， T_k 表示参与监督的目标 token 集合， θ_k 表示对应任务 Adapter 的可训练参数。不同 Agent 可根据其公共输出

契约选择需要参与损失计算的字段，但训练目标始终绑定到期望的 AgentResult。

Agent workflows 负责构造与正式运行一致的模型上下文，但任务路由、视觉视图生成、专家调用和确定性处理不参与反向传播。训练损失仅用于更新对应的 Qwen Adapter；Change Agent 中经训练方案批准的视觉连接参数可以同时更新。

上述 workflow 可概括为算法 4-1。其关键不是改变 Agent 的运行逻辑，而是将正式运行时形成的最终多模态请求直接复用于监督训练，从而缩小训练输入与部署输入之间的分布差异。

算法 4-1 面向 Agent 输入输出边界的工作流对齐微调

输入：训练样本集合 D ；冻结的 VisualTaskPlanner 结果 P ；Agent 集合 $\mathcal{A}$ ；可用视觉专家集合 E ；各任务对应的 Qwen Adapter 参数 $\{\theta_k\}$

输出：微调后的任务 Adapter 参数 $\{\theta_k\}$

```

1: for 每个训练样本  $s \in D$  do
2:    $p \leftarrow$  读取并校验样本  $s$  对应的冻结 Planner 结果
3:    $k \leftarrow p.task$ 
4:    $A_k \leftarrow$  根据任务  $k$  确定性选择对应 Agent
5:    $x \leftarrow$  按统一样本契约构造 Agent 输入  $(s, p)$ 
6:   if  $p.needs\_visual\_assistance = true$  then
7:      $V \leftarrow$  根据  $p$  生成局部视觉视图
8:      $e \leftarrow$  调用  $p$  所请求且系统可用的视觉专家  $E(V)$ 
9:   else
10:     $V \leftarrow$  仅保留 Agent 正式运行所需的基础视觉输入
11:     $e \leftarrow \emptyset$ 
12:   end if
13:    $z \leftarrow A_k(x, V, e)$ 
   构造最终 Qwen 请求：包含正式系统提示、问题、图像及可选专家证据
14:    $y \leftarrow$  按  $A_k$  的公共 AgentResult 契约构造监督目标
15:    $M \leftarrow$  根据任务  $k$  选择参与监督的目标字段及其 token 掩码
16:    $\hat{y} \leftarrow Qwen(z; \theta_k)$ 
17:    $L_k \leftarrow \text{MaskedCausalLMLoss}(\hat{y}, y, M)$ 
18:   反向传播  $L_k$ 
19:   仅更新  $\theta_k$ 
   路由、视觉视图生成、专家调用和确定性处理均不参与反向传播
20: end for
21: return  $\{\theta_k\}$ 

```

4.5.2 General VQA Agent 训练

General VQA Agent 训练数据来自 VRSBench、LRS-VQA 和 SuperRS-VQA，共包含 8,849 条训练记录和 922 条验证记录，覆盖通用视觉问答、场景分类、空间关系和多项选择问答。训练时，样本与 Planner 结果首先进入 General VQA Agent，Agent 按照正式 workflow 选择直接问答或视觉证据辅助路径并组织 Qwen 的实际多模态输入，再以目标 AgentResult 训练 General VQA Adapter。General VQA Agent 的训练配置见表 4-4。

表 4-4 General VQA Agent 主要训练配置

配置项	设置
基础模型	Qwen3.5-9B
微调方式	语言模型 LoRA
LoRA rank	32
LoRA alpha	64
LoRA dropout	0.05
LoRA 目标层	248 个
学习率	1×10^{-4}
优化器	AdamW
学习率调度	cosine, warmup ratio 0.03
训练轮数	2.0
batch size	1
gradient accumulation steps	16
weight decay	0.01
精度	BF16
最大序列长度	16,384
随机种子	42
视觉编码器	冻结
语言模型基础参数	冻结
embedding 与 lm_head	冻结
监督方式	自回归文本生成

4.5.3 Caption Agent 训练

Caption Agent 联合使用 VRSBench 与 XLRS-Bench 数据，共包含 1,570 条训练记录 和 141 条验证记录，其中 VRSBench 训练 1,000 条、验证 111 条，XLRS-Bench 训练 570 条、验证 30 条，每张图像对应一条描述记录。两类数据经过统一问题表达后进入 Caption Agent，由 Agent 按照正式运行方式组织图像和描述请求，再以目标 AgentResult 中的遥感图像描述训练 Caption Adapter。Caption Agent 的训练配置见表 4-5。

表 4-5 Caption Agent 主要训练配置

配置项	设置
基础模型	Qwen3.5-9B
微调方式	语言模型 LoRA
LoRA rank	32
LoRA alpha	64
LoRA dropout	0.05
LoRA 目标层	248 个
学习率	5×10^{-5}
优化器	AdamW
学习率调度	cosine, warmup ratio 0.03
训练轮数	2.0
batch size	1
gradient accumulation steps	16
weight decay	0.01
精度	BF16
最大序列长度	6,144
随机种子	42
视觉编码器	冻结
语言模型基础参数	冻结
embedding 与 lm_head	冻结
监督方式	自回归文本生成

4.5.4 Grounding Agent 训练

Grounding Agent 使用 VRSBench 和 XLRS-Bench 数据，其中训练集分别包含 536 条和 540 条记录，验证集各 60 条，共形成 1,076 条训练记录和 120 条验证记录。训练样本经 Grounding Agent 正式输入路径组织后，以包含目标定位结果的 AgentResult 作为监督目标训练 Grounding Adapter。目标位置以 Agent 公共输出契约规定的文本化坐标字段接受生成监督。Grounding Agent 的训练配置见表 4-6。

表 4-6 Grounding Agent 主要训练配置

配置项	设置
基础模型	Qwen3.5-9B
微调方式	语言模型 LoRA
LoRA rank	32
LoRA alpha	64
LoRA dropout	0.05
LoRA 目标层	248 个
学习率	1×10^{-4}
优化器	AdamW
学习率调度	cosine, warmup ratio 0.03
训练轮数	2.0
batch size	1
gradient accumulation steps	16
weight decay	0.01
精度	BF16
最大序列长度	4,096
随机种子	1234
视觉编码器	冻结
语言模型基础参数	冻结
embedding 与 lm_head	冻结
监督方式	自回归文本生成

4.5.5 Change Agent 训练

Change Agent 使用 LEVIR-CC 数据，共包含 6,465 组训练图像对和 1,242 组验证图像对。训练样本固定按照 T1、T2 顺序输入，并由 Agent 结合任务类型、时间角色和当前决策阶段组织实际多模态请求，再以 ChangeInitialResult 作为监督目标训练 Change Adapter。该结构化结果包含 answer、boxes、evidence_items、geometry 和 status 等字段，分别支持 change_caption 和 change_qa 任务。Change Agent 的训练配置见表 4-7。

训练完成后，适配参数与基础模型统一导出为可独立加载的 Change Agent 模型，并通过模型重载、双图像前向推理和真实样本验证。该模型作为 Change Agent 的主要语义理解模块，用于双时相变化描述、变化问答和 LEVIR-CC 评测。

为补充局部变化区域的空间证据，项目独立训练 ChangeHead 辅助变化感知模块。Qwen Change Adapter 负责变化语义理解与文本生成，ChangeHead 通过 T1、T2 图像及像素级变化标注学习变化响应，负责提供“变化发生在哪里”的空间线索。两者分别训练，不进行端到端联合反向传播；ChangeHead 输出仅作为辅助证据，不替代 Qwen 作出最终语义判断。ChangeHead 的训练配置与验证结果见表 4-8。

表 4-7 Change Agent 主要训练配置

配置项	设置
基础模型	Qwen3.5-9B
微调方式	语言模型 LoRA 与视觉连接适配
LoRA rank	64
LoRA alpha	128
LoRA dropout	0.05
语言模型 LoRA 学习率	1×10^{-4}
视觉连接部分学习率	1×10^{-5}
训练轮数	1.0
batch size	1
gradient accumulation steps	8
精度	BF16
视觉编码器主干	冻结
语言模型基础参数	冻结
监督方式	自回归结构化文本生成
最终 global step	12,845
验证集 eval_loss	0.20759

表 4-8 ChangeHead 主要训练配置与验证结果

配置项	设置
训练样本	6,465 组
验证样本	1,242 组
最大训练轮数	30
batch size	4
初始学习率	3×10^{-4}
weight decay	1×10^{-4}
gradient clipping	1.0
精度	AMP 混合精度
early stopping patience	6
实际停止轮数	第 27 个 epoch
最佳 checkpoint	第 21 个 epoch
Precision	0.8644
Recall	0.8676
F1	0.8660
IoU	0.7636

在 632 个无变化验证场景中，ChangeHead 有 66 个样本产生场景级误报，误报率约为 10.44%。该结果表明，ChangeHead 能够提供较细粒度的局部变化证据，但仍会受到图像配准误差、边缘差异和局部纹理变化的影响。因此，当前 LEVIR-CC 全量变化描述评测仍由双时相 Qwen Change Adapter 完成最终文本生成，ChangeHead 用于支持区域提示、变化证据融合和局部二次验证。

第五章 面向单粒子翻转的模型权重容错与恢复方案

5.1 问题描述与设计目标

卫星在轨运行过程中长期暴露于复杂空间辐射环境，高能质子、重离子及其他高能粒子可能穿透电子设备并作用于存储器或计算器件，引发单粒子效应 [13, 14]。其中，单粒子翻转（Single Event Upset, SEU）可能导致存储单元中的二进制数据由“0”变为“1”或由“1”变为“0”。该类错误通常不会造成器件永久损坏，但如果发生在神经网络模型权重所在的存储区域，错误参数可能持续参与后续推理计算，并经 Transformer 多层结构逐级传播，最终导致遥感目标识别错误、问答答案偏移、图像描述异常，严重时还可能造成 NaN、Inf 等数值异常甚至推理任务失效。

对于传统小规模神经网络，可以采用 ECC、双模冗余或三模冗余等方式提高可靠性，但多模态大模型参数规模大、访存量高，若对全部模型参数进行完整冗余，会显著增加星载存储、显存占用、计算时延及能耗，并不适用于算力、存储和能源均受约束的卫星平台。已有研究表明，Transformer 模型内部不同模块以及浮点权重不同二进制位对于 Bit Flip 的敏感程度存在明显差异，其中少量高敏感参数往往会产生远大于普通参数的故障传播效应，因此基于脆弱性分析实施选择性保护具有较好的性能—资源折中 [15]。

结合本项目 M³-RS 当前采用的 Qwen3.5-9B 多模态基座和多 LoRA Adapter 运行方式，本章设计一种面向星载部署的轻量化权重容错方案。M³-RS 当前已经具备模型 logical_id、权重 SHA-256、Adapter 资产校验和运行身份管理机制，并采用单基座、多 Adapter 的模型组织方式。在此基础上，本方案进一步面向在轨单粒子软错误，形成“软件故障注入—影响评估—完整性校验—关键权重保护—故障恢复”的闭环。

本方案的设计目标并不是模拟高能粒子在半导体材料中的完整物理输运过程，而是在模型软件层对空间辐射产生的最终数字效应进行抽象，即直接模拟模型权重二进制位的随机翻转。通过这种方式，可以在现有 GPU/PyTorch 环境中快速开展故障敏感性评估，并为后续面向具体星载处理器的硬件级可靠性设计提供依据。

5.2 总体技术方案

本方案采用“离线评估、在线校验、按需恢复”的总体思路。

在模型部署前，通过软件方式随机选取模型权重及其二进制位实施 Bit Flip，分别考察视觉编码器、Embedding、Attention、MLP、归一化层以及 LoRA Adapter 等不同模块受到单粒子翻转后的性能变化，并进一步区分 Sign、Exponent 和 Mantissa 不同 bit 区域的敏感程度。在此基础上形成模型权重脆弱性清单，为选择性保护确定优先级。

模型部署后，首先利用项目已有 SHA-256 机制确保加载的模型 checkpoint 与 Adapter 文件本身正确；模型进入运行状态以后，再对选定的高风险权重实施轻量完整性校验。当检测到权重发生异常变化时，不重新加载整个大模型，而是从经过校验的本

地 Golden Checkpoint 中恢复异常权重，并重新执行当前推理任务。

因此，整个容错过程可概括为：BitFlip 故障模拟与注入 → 脆弱性评估与权重识别 → 错误校验与选择性保护 → 故障恢复与重推理。




图 5-1 星载权重容错总体技术路线

该方案避免了传统全模型 TMR 等高冗余方法带来的巨大存储和计算开销，更符合卫星平台长期自主运行条件下“有限资源优先保护关键参数”的设计原则。

5.3 单粒子翻转的软件故障注入方法

5.3.1 Bit Flip 故障模型

模型权重在计算机系统中最终以二进制形式存储，因此单粒子翻转可以在软件层表示为某个权重二进制位执行一次异或操作。设模型权重 w_i 对应的二进制表示为 u_i ，随机选择第 k 位，则故障注入可表示为

$$\hat{u}_i = u_i \oplus (1 \ll k), \quad (5.1)$$

其中， $\oplus$ 表示按位异或， k 表示发生翻转的 bit 位置。随后将修改后的二进制数据重新解释为原有 FP32、BF16 或 FP16 数值，即得到发生软错误后的模型权重 $\hat{w}_i$ 。

这种方法和普通的高斯噪声扰动存在本质区别。高斯扰动通常只会使参数产生连续的小幅变化，而单个高阶 bit 的翻转可能使模型权重突然跨越多个数量级。LLM Bit Flip 研究同样采用对模型权重二进制表示直接进行 XOR 的方式构建软错误模型 [16]。

第一阶段主要研究存储型权重错误。即假定 SEU 导致一个模型权重发生 Bit Flip，并在该权重被校验和重新写入之前持续存在。计算单元中的瞬态错误、激活值瞬态翻转

以及一次粒子作用造成的多位翻转等问题，可在后续面向具体星载硬件时进一步扩展。通过适当收缩故障模型范围，可以将本阶段重点集中在赛题明确要求的权重错误影响、错误校验和模型恢复问题上。

5.3.2 不同浮点位的差异化故障模拟

对于浮点权重而言，不同 bit 对实际数值的贡献差异很大。以本项目重点使用的 BF16 为例，其 16 个二进制位分别由 1 位符号位、8 位指数位和 7 位尾数组成。不同浮点格式的权重规模与故障影响对照见表 5-1。

表 5-1 不同浮点格式下的权重规模与故障影响对照

配置	模型大小	峰值显存	P95 时延	任务指标变化
FP32	32	1	8	23
BF16	16	1	8	7
FP16	16	1	5	10

在 IEEE 754 浮点格式中，数值可表示为

$$w = (-1)^S \times 2^{E-E_{\text{bias}}} \times (1 + M), \quad (5.2)$$

其中 S 、 E 和 M 分别代表 Sign、Exponent 和 Mantissa。

Sign 位翻转主要改变参数正负；Mantissa 位通常只改变有限精度范围内的权重值，而指数位尤其是高阶指数位发生翻转后，可能导致参数数值成倍甚至成指数级放大。已有 GPT-2 实验显示，最高指数 bit 的翻转对于模型性能影响最显著，而多数低位和 Mantissa BitFlip 对模型影响明显较小 [16]。LOST-ViT 的相关研究也发现，高影响指数位发生单次软错误即可造成显著模型精度下降 [15]。

因此，本项目不采用单一的随机 Bit Flip 评价方式，而计划分别开展三组故障注入：Sign Flip、Exponent Flip、Mantissa Flip。通过比较三类故障对遥感任务推理结果的影响，可以进一步判断是否有必要将有限保护资源集中用于指数位等高风险数据。

5.3.3 不同模型模块的故障注入

Transformer 模型内部参数量巨大，如果仅给出整个模型平均 Bit Flip 性能下降，很难进一步指导实际容错设计。因此，本方案按照模型功能模块对故障注入位置进行分组。

结合当前 M³-RS 模型构成，拟重点分析以下参数区域，如表 5-2 所示。

表 5-2 不同模型模块的故障注入分组与主要分析内容

模型区域	典型参数	主要分析内容
视觉编码模块	Vision Encoder、视觉投影参数	遥感视觉特征对 Bit Flip 的敏感性
Embedding	Token/Position Embedding	输入阶段权重错误的级联传播
Attention	Q/K/V/O Projection	Attention 权重错误对跨 Token 信息交互的影响
MLP	Gate/Up/Down Projection	大规模线性计算中的错误传播
Norm	LayerNorm/RMSNorm 参数	数值归一化过程的稳定性
LoRA Adapter	LoRA-A、LoRA-B	任务专用增量权重发生故障后的性能变化

这一划分也与当前 M³-RS 的模型组织方式具有良好对应关系。现有系统使用一套 Qwen3.5 基座，同时通过不同 LoRA Adapter 对 Planner 和领域 Agent 进行任务适配。因此，本方案将进一步比较 Base 权重故障和 LoRA 权重故障两种情况。

这一区分具有明显的星载应用意义。基座模型是多个任务共同使用的基础能力，一处关键参数错误可能影响多个 Agent；LoRA 参数规模较小，但与具体任务能力联系更加紧密。通过分别研究两类权重，可以为后续“基座模型选择性保护、LoRA 完整保护”的分级可靠性策略提供依据。

5.4 单粒子翻转影响评估与关键权重识别

5.4.1 脆弱性评价

软错误保护不应默认模型中的每个参数具有相同的重要程度。已有 Vision Transformer 研究表明不同模型层、模块甚至 Attention Head 对软错误的敏感性均呈现明显非均匀性，因此通过脆弱性评估指导选择性保护，可以降低容错机制的额外开销。

本项目计划在无故障条件下首先获得模型基准性能 M_{clean} ，随后对指定模块独立执行多次随机 Bit Flip，得到对应的故障性能 M_{fault} 。对于指标越高表示性能越好的任务，可以定义模块 c 的相对脆弱性分数：

$$V_c = \frac{1}{R} \sum_{r=1}^R \frac{M_{\text{clean}} - M_{\text{fault},c}^{(r)}}{M_{\text{clean}} + \varepsilon}, \quad (5.3)$$

其中， R 为该模块独立故障注入次数， ε 为防止分母为零的极小值。

V_c 越高，说明该模型模块受到 Bit Flip 后越容易导致最终任务性能下降，应获得更高的保护优先级。进一步将模块类型和 bit 类型结合，可以形成模块—bit 二维脆弱性指标

$$V(c, b), \quad (5.4)$$

其中 c 表示模型模块， b 表示 Sign、Exponent 或 Mantissa。最终形成“模块—bit 二维脆弱性图谱”，为后续保护策略提供直接依据。

5.4.2 结合遥感多任务进行影响评价

本项目的模型并非单一分类网络，而是同时承担目标定位、场景分类、语义理解、变化检测、目标计数和图像描述等不同任务，因此不能只使用 Top-1 Accuracy 衡量 Bit Flip 的影响。

故障评估将尽量复用 M³-RS 当前已经建立的统一 evaluation 体系，在同一测试样本、Prompt 和模型配置下分别获得无故障与故障条件的结果。M³-RS 当前已经将多类遥感任务纳入统一运行、评测和结果工件体系。

根据不同任务分别使用相应指标，例如场景分类和选择题使用 Accuracy，Grounding 使用 IoU 或定位成功率，目标计数使用计数准确率或 MAE，Caption 使用 BLEU、METEOR、ROUGE-L、CIDEr 等现有指标。通过将各任务性能变化归一化后，可以进一步研究不同模型模块的软错误是否具有任务相关性。

在模型可靠性层面，还计划增加 Silent Data Corruption (SDC) 统计。若发生 Bit Flip 后模型仍能够完成推理，但答案相对于无故障结果已经发生错误，并且系统未产生任何异常信号，则将该样本记为一次 SDC。对于星载自主智能系统而言，SDC 比直接程序崩溃更加值得关注，因为其结果在形式上仍然“正常”，容易继续传递到后续决策链路。

5.5 权重错误校验机制

5.5.1 模型文件级 SHA-256

当前 M³-RS 已实现本地 checkpoint 优先、PEFT Adapter 资产检查、logical_id、精确 SHA-256 以及运行身份校验等机制。因此，模型正式加载前继续使用 SHA-256 对 checkpoint 和 Adapter 文件进行完整性验证，确保部署使用的模型版本没有在传输、存储或更新过程中发生异常。

该过程可表示为

$$\text{SHA256}(W_{\text{load}}) \stackrel{?}{=} \text{SHA256}(W_{\text{golden}}), \quad (5.5)$$

若摘要值不一致，模型直接拒绝加载。

但是，该方法主要用于验证磁盘或固态存储中的模型文件。一旦模型正确加载到内存、显存或其他星载计算存储设备后，再发生单粒子翻转，磁盘 checkpoint 本身仍然可能保持正确，因此仅依赖文件 SHA-256 不能解决在轨运行过程中的软错误问题。

5.5.2 运行时关键权重 Checksum

为此，本项目拟增加轻量级运行时权重校验。模型部署前，对需要保护的关键权重张量 W_i 计算 CRC32 等快速 Checksum：

$$C_i = \text{CRC32}(W_i), \quad (5.6)$$

同时生成保护清单：

$$\mathcal{P} = \{\text{name}_i, \text{shape}_i, \text{dtype}_i, C_i\}. \quad (5.7)$$

模型运行期间按照设定周期重新计算：

$$C'_i = \text{CRC32}(W'_i). \quad (5.8)$$

如果出现

$$C'_i \neq C_i, \quad (5.9)$$

则认为该权重已经发生异常改变，并触发模型恢复机制。

该方法与 SHA-256 的作用不同。SHA-256 负责模型部署和加载阶段的版本及文件完整性验证，Checksum 则用于运行期间快速判断关键模型参数是否发生变化。

Transformer 软错误研究已经使用 algorithmic checksum 对关键计算或参数异常进行检测，并结合选择性保护降低运行开销 [17]。

考虑到星载平台不宜持续扫描整个大模型，本项目第一阶段计划仅对高优先级权重实施周期校验，而不是在每次推理过程中重新检查数十亿参数。校验周期可以根据模型任务负载和星载平台性能进一步设置，例如在模型加载后、任务批次之间或运行一定推理次数后进行一次校验，从而降低对正常推理吞吐的影响。

5.5.3 数值异常辅助检测

除权重 Checksum 外，本项目计划加入一种几乎不增加模型参数量的快速异常检测方式，即监测推理过程中是否出现 NaN、Inf 等非有限数值。

Bit Flip 尤其是指数位翻转可能使原本正常的数值突然变成极大值、Inf 或 NaN，并在后续 Attention 和 MLP 计算中快速传播。相关 ViT 研究发现，NaN、Inf 以及异常大数值与故障率增加存在明显相关性，简单的非有限值和越界值检测可以作为有效的软件级故障感知手段 [18]。

因此，数值健康检测主要作为 Checksum 的快速触发信号：当模型计算过程中发现 NaN/Inf 时，可提前启动关键权重校验，而不必等待下一个固定校验周期。

这一设计不承担精确故障定位功能，而是用于缩短严重软错误的发现时间。

5.6 关键权重选择性保护与模型故障恢复

5.6.1 分级选择性保护

从可靠性角度看，最直接的保护方法是对全部模型权重做双份或三份冗余，但对于 9B 级多模态大模型而言，该方法需要显著增加模型存储和显存资源，因此并不适合当前卫星平台受限算力和受限存储条件。

LOST-ViT 等研究表明，通过模型脆弱性分析只保护敏感层或关键参数，可以在较小资源开销下获得更好的软错误保护收益 [15]。

结合 M³-RS“单基座、多 LoRA”的结构，本项目拟采用两级权重保护：LoRA Adapter 全量保护 + Base Model 关键权重选择性保护。

LoRA 参数量相对于完整 Qwen3.5 基座模型较小，因此对当前实际使用的 Adapter 进行完整 Checksum 管理成本较低；对于参数量较大的 Base Model，则根据第 4.4 节的脆弱性分数 V_c 进行排序，仅将高风险权重加入保护清单。

保护比例拟比较 Top 5%、Top 10% 和 Top 20% 等不同等级，最终根据后续目标平台资源测试选择适合的配置。

这一机制的核心并不是假设某个特定 Transformer 层一定最重要，而是先通过 M³-RS 实际模型故障注入得到脆弱性，再决定保护谁。从而避免直接照搬 ViT、GPT-2 等其他模型上的脆弱性结论。

5.6.2 Golden Checkpoint 恢复

错误校验只能发现问题，无法自动恢复被翻转 bit 的正确取值。因此，本项目将经过 SHA-256 验证的本地模型 checkpoint 作为 Golden Weight Source。

当运行时 Checksum 检测到某个受保护权重张量发生异常后，根据 Tensor 名称从本地 Golden Checkpoint 中重新读取正确参数：

$$W'_i \leftarrow W_i^{\text{golden}}, \quad (5.10)$$

恢复完成后再次执行：

$$\text{CRC32}(W'_i) \stackrel{?}{=} \text{CRC32}(W_i^{\text{golden}}). \quad (5.11)$$

只有当校验重新通过时，才认为模型恢复成功。

与重新加载整个 Qwen3.5 模型相比，这种方式只恢复异常的 Tensor 或 Adapter，可以显著减少模型恢复期间的读写量和等待时间。

当前 M³-RS 本身已经要求模型和 Adapter 具有明确 logical_id、版本和 SHA，因此 Golden Checkpoint 不是额外引入的一套未知备份，而是与模型部署版本严格绑定的可信权重源。

5.6.3 故障恢复后的重推理

如果权重错误发生在一次遥感任务推理过程中，即使错误权重已经成功恢复，当前已经得到的输出仍然可能受到故障影响。因此，本方案在恢复后对当前样本执行一次重新推理。

整体过程为：检测异常 → 定位异常权重 → Golden Weight 恢复 → 再次 Checksum → 重新推理。

为了避免极端情况下不断重试，每条任务最多触发一次自动故障恢复与重推理；若再次失败，则将其记录为模型故障并进入上层异常处理，而不是持续进行无界重试。

这种“按需恢复、仅故障时产生额外计算”的方式，特别适合软错误总体属于低概率

事件的星载运行环境。

5.7 面向卫星平台的轻量化设计

本方案在设计过程中重点考虑星载平台模型规模大、存储有限、算力受限和长期无人值守等特点，因此不采用全模型复制方式，而通过选择性保护控制资源开销。

首先，在存储方面，Golden Checkpoint 与模型正常部署所需本地 checkpoint 复用，不在 GPU 显存中额外维护完整权重副本。运行时增加的永久数据主要是关键权重保护清单和对应 Checksum。若保护 N 个 Tensor，使用 CRC32 时仅需要约 $4N$ Bytes 的 Checksum 信息，除此之外只需要保存 Tensor 名称、shape 和 dtype 等少量元数据。

其次，在计算方面，Checksum 不需要参与 Transformer 每一次矩阵运算，而是按照一定周期对关键权重进行顺序扫描。因此其计算开销主要与受保护参数量有关，而不是与完整模型参数量直接相关。通过调整保护比例和校验周期，可以在可靠性与推理吞吐之间灵活折中。

再次，故障恢复属于事件触发过程。在没有发生错误的情况下，不产生额外模型推理；只有检测到权重异常时才从 Golden Checkpoint 读取相应权重并重新计算当前样本。因此正常运行阶段不会引入 TMR 那样持续存在的数倍计算开销。

考虑到当前 M³-RS 后续还计划评估 BF16/FP16、INT8 和 INT4 等模型部署形式，本方案的 Bit Flip 和 Checksum 机制也按照“二进制表示无关”的思路设计。未来模型从 BF16 进一步量化为 INT8/INT4 后，只需调整故障注入时的 bit 解析方式和对应脆弱性评价，不需要改变整个容错流程。

从卫星长期运行角度看，该方案具有三个特点：一是避免全模型冗余带来的显存和存储膨胀；二是校验和恢复均可以脱离训练过程独立执行，不需要在轨重新训练大模型；三是故障检测、位置和恢复过程均可以形成日志，为卫星在轨健康管理 and 后续故障分析提供依据。

5.8 故障容错实验设计

实验拟采用“Clean—Faulty—Protected”三组对照。

Clean 组使用完全未注入故障的模型，用于建立各遥感任务的正常性能基线；Faulty 组按照预定位置和 Bit Flip 数量注入模型软错误，不启用保护机制，用于评估不同权重故障对模型推理的影响；Protected 组在完全相同的 Bit Flip 条件下开启 Checksum 和 Golden Weight Recovery，用于评价错误检测与恢复机制有效性。

计划采用的主要实验变量见表 5-3。

表 5-3 故障容错实验主要变量设置

实验维度	计划设置
模型权重格式	BF16 为主，后续扩展 FP16/INT8
故障类型	Single Bit Flip
Bit 区域	Sign/Exponent/Mantissa
注入位置	Vision/Embedding/Attention/MLP/Norm/LoRA
参数类型	Base Model/LoRA Adapter
故障数量	1、10、100 个 Bit，辅以 BER 压力测试
保护比例	0%、Top 5%、Top 10%、Top 20%
对比模式	Clean/Faulty/Protected
重复方式	固定随机种子，多次独立随机注入

在数据集方面，不再单独构造新的遥感标注数据，而是从 M³-RS 当前已接入的公开遥感任务数据中构建故障评估子集。项目现有数据链已经支持 VRSBench、XLRS、MME-RealWorld、LEVIR-CC 等数据来源，并覆盖单图、超大图和双时相图像。后续将从不同任务中按固定规则抽取代表性样本，并冻结图像、问题、Prompt、解码参数和模型版本，确保 Clean、Faulty 和 Protected 三组之间唯一变化因素为模型软错误及其保护机制。

软件故障实验首先使用固定随机种子保证可重复性，每次完成一次故障注入和推理后立即恢复模型原始权重，再进行下一次独立试验，避免前一次错误累积影响后续实验。

后续实验重点记录四类指标：第一类为任务性能变化，即故障前后 Accuracy、IoU、BLEU、CIDEr 等指标变化；第二类为可靠性指标，包括故障检测率、SDC 比例、恢复成功率以及 NaN/Inf 出现比例；第三类为性能开销，包括 Checksum 校验时延、故障恢复时延及重推理时延；第四类为资源开销，包括额外 CPU 内存、GPU 显存和保护元数据占用。

通过这些实验，可以最终回答三个问题：

- (1) 单粒子 Bit Flip 会在多大程度上影响 M³-RS 多模态遥感任务？
- (2) 哪些模型模块和 bit 位最值得优先保护？
- (3) 在有限的星载计算和存储开销下，选择性保护可以恢复多少模型可靠性？

5.9 方案创新点

本章方案的创新性首先体现在面向多模态遥感大模型而非传统 CNN 开展模型软错误可靠性设计。现有相关工作较多针对 ViT、BERT 或小规模 Transformer，本项目则围绕实际遥感多任务智能体中的 Qwen3.5 多模态基座以及多 LoRA Adapter 结构进行故障建模，在目标定位、计数、场景理解、变化分析和图像描述等多种任务上统一研究模型权重错误传播。

第二，提出 Base Model 与 LoRA Adapter 分级保护机制。利用 M³-RS 单基座、多 Adapter 的模型结构，将规模较小、与具体任务紧密关联的 LoRA 权重进行完整保护，而对于参数规模巨大的基座模型则根据实际脆弱性评估选择性保护关键参数，从而避免对全部 9B 模型实施高成本冗余。

第三，采用模型模块—浮点 bit 双粒度脆弱性评价。不仅研究某个模型层是否容易受到 Bit Flip 影响，还进一步区分 Sign、Exponent、Mantissa 不同 bit 区域，将模型结构敏感性和数值表示敏感性结合起来，为后续指数位重点保护、模型量化容错和星载存储优化提供依据。

第四，形成“SHA-256 静态完整性校验 +Checksum 运行时校验 +Golden Weight 局部恢复”的多级可靠性机制。SHA-256 用于保证加载模型版本正确，Checksum 用于检测运行期间的软错误，Golden Checkpoint 用于按需恢复异常权重。三者职责分离，可以在不改变模型主体架构和训练方法的情况下形成完整的软错误处理闭环。

最后，该方案具有明显的卫星平台适配特征。通过选择性保护、周期校验和事件触发恢复，将容错开销限制在有限范围内，不需要维护多套完整模型，也不需要重新训练模型，能够较好兼顾星载遥感大模型的智能能力和长期运行可靠性。

5.10 总结

针对空间高能粒子可能引发的模型权重单粒子翻转问题，本章设计了一种面向星载多模态遥感大模型的轻量化权重容错方案。方案首先利用软件 Bit Flip 模拟模型权重存储软错误，并分别从模型模块和浮点 bit 类型两个维度评价模型脆弱性；随后根据脆弱性结果确定关键权重保护范围，在已有 SHA-256 模型完整性机制基础上增加运行时 Checksum；当检测到权重异常时，从经过验证的 Golden Checkpoint 中恢复异常参数，并重新执行当前遥感推理任务。

整个方案形成“故障注入-影响评估-错误校验-选择性保护-故障恢复”的完整技术链路。

该方法强调以较低计算和存储开销保护对模型推理最关键的少量参数，不依赖全模型冗余，也不需要修改现有模型训练结构，能够较好适配卫星平台有限显存、有限存储、有限功耗以及长期无人值守运行的应用特点。

第六章 测试方案与结果

6.1 评测设置

本项目采用 VRSBench、XLRS-Bench、MME-RealWorld-RS 和 LEVIR-CC 四个公开遥感数据集评测系统性能，覆盖视觉问答、图像描述、目标定位、目标计数与双时相变化描述等任务。其中，MME-RealWorld 仅使用 Remote Sensing 子集；XLRS-Bench VQA 和 MME-RealWorld-RS 均未参与对应 Agent 训练，用于考察系统的 zero-shot 迁移能力。

在评测指标方面，视觉问答与分类任务采用 Exact Match 或 Accuracy；目标定位采用 Acc@0.5 与 Mean IoU；描述生成采用 BLEU-1 至 BLEU-4、METEOR、ROUGE-L 和 CIDEr；目标计数采用 Exact Count Accuracy 与 MAE。除 CIDEr 外，各项指标均以 0 至 1 入库，并在表中按百分制显示；CIDEr 同样乘 100 展示，以便统一表格量级，但不与 Accuracy 等指标作数值上的直接比较。

除确定性指标外，本项目使用 Qwen3.5-Flash 开展文本语义评测。Judge 仅接收原始问题、一个或多个标准答案以及模型答案。针对 VQA、Caption、Change Caption 和 Counting 分别设置任务专用评分准则；每条样本独立评测 3 次，每次输出 1 至 5 分，取三次评分均值后线性映射到 0 至 100 分。具体 Prompt、采样配置、裁决 Schema 和聚合方法见附录 D。

6.2 综合评测结果

表 6-1 M³-RS 综合评测结果（一）：问答与计数

数据集	任务	测试规模	外部评测	EM/Acc	备注
VRSBench	VQA	35,822	84.15	58.83	
	Counting	5,480	72.75	46.61	
XLRS-Bench	VQA	3,060	69.32	58.99	Zero-shot
MME-RealWorld-RS	Color	1,253	75.83	68.24	Zero-shot
	Counting	1,226	38.83	19.00	Zero-shot
	Position	1,256	59.03	46.58	Zero-shot

表 6-1（续） M³-RS 综合评测结果（二）：描述与定位

数据集	任务	测试规模	外部评测	BLEU-1	BLEU-4	METEOR	ROUGE-L	CIDEr	Acc@0.5	Mean IoU
VRSBench	Caption	7,195	45.16	39.56	8.66	19.77	29.11	22.53	—	—
	Grounding	15,725	—	—	—	—	—	—	71.92	61.70
XLRs-Bench	Caption	634	28.42	46.99	16.03	24.36	28.40	1.63	—	—
	Grounding	2,727	—	—	—	—	—	—	18.37	16.43
LEVIR-CC	Change Caption	1,333	80.33	60.21	31.43	40.73	47.04	23.46	—	—

注：测试规模指获得有效预测并进入相应指标统计的样本数量。“—”表示指标不适用于对应任务。结果表明，M³-RS 在颜色识别、VRSBench 目标定位、遥感图像描述和双时相变化描述方面表现出较稳定的任务能力。

6.3 VRSBench 评测结果与分析

VRSBench 采用 validation 数据进行评测。Caption 和 Grounding 分别按照对应任务的参考描述与水平框标注进行确定性评测。HBB Grounding 将官方 0 至 100 坐标等价转换到系统统一的 0 至 999 左上角原点坐标系，并使用轴对齐 IoU 计算定位结果。

表 6-2 VRSBench 评测结果

任务	测试规模	外部评测	EM	BLEU-1	BLEU-2	BLEU-3	BLEU-4	METEOR	ROUGE-L	CIDEr	Acc@0.5	Mean IoU	MAE
VQA	35,822	84.15	58.83	—	—	—	—	—	—	—	—	—	—
Caption	7,195	45.16	—	39.56	23.12	13.84	8.66	19.77	29.11	22.53	—	—	—
Grounding	15,725	—	—	—	—	—	—	—	—	—	71.92	61.70	—
Counting	5,480	72.75	46.61	—	—	—	—	—	—	—	—	—	0.98

VRSBench Grounding 的 Acc@0.5 达到 71.92%，Mean IoU 达到 61.70%，是当前评测中表现较稳定的空间定位任务。这说明多数有效预测不仅能够越过 0.5 IoU 阈值，而且预测框与目标区域整体保持了较好的重合程度。Grounding Agent 的训练记录约为 1,076 条，其中包含 VRSBench 同源训练数据；任务输出形式相对集中，有助于模型学习目标描述与坐标表达之间的对应关系。

Caption 在 7,195 条样本上取得 39.56 的 BLEU-1、19.77 的 METEOR 和 29.11 的 ROUGE-L，表明生成结果能够覆盖参考描述中的主要地物语义。随着 n-gram 阶数提高，BLEU-4 下降至 8.66，说明较长短语、语序组织和细节组合与参考描述之间仍存在差异。Caption 训练数据总计 1,570 条，其中 1,000 条来自 VRSBench；相对较小的同源训练数据为任务适配提供了基础，但其场景和表达多样性仍可能限制更长描述的稳定生成。

VQA 合并评测包在 35,822 条有效预测上的 Exact Match 为 58.83%，说明系统已经具备覆盖多类遥感问题的综合问答能力，但不同问题类型之间仍存在明显差异。General VQA Agent 使用 VRSBench、LRS-VQA 和 SuperRS-VQA 等来源的 8,849 条训练记录，数据来源相对多样，有助于覆盖颜色、类别、存在性和场景判断等常见问题；而精确数量、细粒度位置和尺寸判断对局部视觉证据与答案归一化提出了更高要求。VRSBench Counting 已在官方 EVAL 计数子集 6,374 问上完成评测，进入指标统计的 5,480 条样本的 Exact Count Accuracy 为 46.61%、MAE 为 0.98（见表 6-2）。运行过程中少量样本因规划输出校验或模型调用异常未形成有效预测，相关失败记录已保留用于复核。

6.4 XLRS-Bench 评测结果与分析

本节使用 XLRS-Bench 中的视觉问答、图像描述和目标定位数据，对系统处理超高分辨率遥感影像的能力进行评测。其中，视觉问答数据为 zero-shot 评测；图像描述和目标定位数据则分别用于 Caption Agent 与 Grounding Agent 的任务适配和测试。XLRS-Bench 涵盖大幅遥感场景、细粒度地物描述及复杂空间指代，可用于考察模型在高分辨率输入下的场景理解、文本生成和目标定位能力。

表 6-3 XLRS-Bench 评测结果

任务	测试规模	外部评测	EM	BLEU-1	BLEU-2	BLEU-3	BLEU-4	METEOR	ROUGE-L	CIDEr	Acc@0.5	Mean IoU	备注
VQA	3,060	69.32	58.99	—	—	—	—	—	—	—	—	—	Zero-shot
Caption	634	28.42	—	46.99	30.48	21.41	16.03	24.36	28.40	1.63	—	—	
Grounding	2,727	—	—	—	—	—	—	—	—	—	18.37	16.43	

XLRS-Bench VQA 在 zero-shot 条件下取得 58.99% 的 Exact Match，表明系统在未使用 XLRS VQA 数据训练的情况下，仍能够将既有遥感问答能力迁移到超高分辨率图像。与之相比，Caption 使用 570 条 XLRS 训练记录进行任务适配，在 634 条测试样本上取得 46.99 的 BLEU-1、16.03 的 BLEU-4 和 24.36 的 METEOR，说明模型能够识别并概括大幅遥感影像中的主要场景内容。其 CIDEr 仅为 1.63，与 BLEU 和 METEOR 呈现明显分化，表明生成文本虽然覆盖了部分局部词汇与短语，但对参考描述中更具区分性的表达复现不足；该差异还可能受到参考描述数量、长文本结构和测试样本组成的影响。

Grounding 的 Acc@0.5 为 18.37%，Mean IoU 为 16.43%，明显低于 VRSBench Grounding。Grounding 训练记录总计约 1,076 条，其中 XLRS 约 540 条；相对于 XLRS 图像中的目标尺度、空间指代和场景组合多样性，这一训练规模可能尚不足以充分覆盖细粒度定位模式。同时，超高分辨率图像中的小目标细节、跨区域参照关系、局部区域选择和坐标回映误差也可能共同影响定位表现。上述因素属于结合训练配置与错误特征作出的解释，尚不能作为单一因素的因果结论。

6.5 MME-RealWorld-RS 评测结果与分析

为考察 VQA Agent 的跨数据集泛化能力，本项目在 MME-RealWorld 的 Remote Sensing 子集开展 zero-shot 评测。该子集未用于模型训练、Adapter 微调、Prompt 选择、阈值设定或结果校准，也未将标注答案作为 few-shot 示例。评测分别统计颜色识别、目标计数和空间关系三个子任务，并报告样本加权 Micro Average 与三类任务等权 Avg-C。

表 6-4 MME-RealWorld-RS zero-shot 评测结果

子任务	测试规模	外部评测	Accuracy
Color Recognition	1,253	75.83	68.24
Object Counting	1,226	38.83	19.00
Spatial Relationship/Position	1,256	59.03	46.58
Micro Average	3,735	58.04	44.79
Avg-C	3 类	—	44.94

结果显示，系统的 zero-shot 迁移能力具有明显的任务依赖性。颜色识别 Accuracy

达到 68.24%，说明颜色等局部视觉属性能够较稳定地迁移；空间关系任务 Accuracy 为 46.58%，反映目标与参照区域的联合理解仍具有一定难度；目标计数 Accuracy 仅为 19.00%，是三个子任务中的主要短板。虽然 General VQA Agent 拥有 8,849 条、来源较为多样的训练记录，但总体训练规模并不等同于对 MME 计数分布的充分覆盖。精确计数还依赖小目标识别、类别粒度、重复目标去除及选项映射，因而比颜色属性识别更容易受到跨数据集分布差异影响。Micro Average 与 Avg-C 较为接近，说明总体结果没有因三个子任务样本规模的轻微差异而发生明显偏移。3,738 条输入中有 3,735 条形成有效预测，其余 3 条因模型调用异常未进入指标统计。

6.6 LEVIR-CC 评测结果与分析

当前 LEVIR-CC 结果基于 validation 划分的 1,333 个双时相图像对，使用 T1、T2 固定输入顺序生成变化描述。描述指标采用项目统一的 pycocoevalcap 评测实现。另一份自包含 BLEU 实现仅作为内部核验，不进入本报告的正式结果。

表 6-5 LEVIR-CC 变化描述评测结果

任务	测试规模	外部评测	BLEU-1	BLEU-2	BLEU-3	BLEU-4	METEOR	ROUGE-L	CIDEr
Change	1,333	80.33	60.21	50.72	41.48	31.43	40.73	47.04	23.46

LEVIR-CC 上的 BLEU-4 达到 31.43，METEOR 和 ROUGE-L 分别达到 40.73 和 47.04，表明系统能够较稳定地生成与参考答案一致的建筑变化描述。Change Agent 训练使用 6,465 个训练图像对，并由图像对构造多条变化描述与变化问答监督；相对充足的同源训练数据、固定的双时相输入顺序和较集中的建筑变化表达模式可能共同促进了当前结果。由于 LEVIR-CC 具有不同于单图详细描述任务的数据组织方式和参考文本分布，本节不将其指标与 VRSBench 或 XLRs Caption 作直接优劣排序。本次 1,333 条样本的 Planner 解析、任务路由和 Change Agent 推理均成功完成。

6.7 分层对照分析

为进一步考察 M³-RS 的视觉辅助机制及跨数据集适应能力，本节从 Planner 视觉辅助路径和跨数据集 VQA 迁移两个维度开展分层对照。VRSBench VQA 合并评测覆盖官方 validation 集合中的 36,934 条问题，其中 35,822 条形成有效预测；XLRs-Bench VQA 共有 3,060 条有效预测。视觉辅助路径分析仅纳入同时具有有效预测、Planner 记录和确定性评测结果的样本。由于视觉辅助路径由 Planner 根据样本内容自动选择，相关结果属于观察性分组，用于分析不同机制与任务表现之间的关系，不作为严格的开关式消融结论。

6.7.1 视觉辅助路径对照

为减少视图裁剪差异的影响，本节将输入视图固定为完整图像，并在相同问题类型内部比较 Planner 是否启用视觉辅助。

表 6-6 VRSBench VQA 典型问题的视觉辅助路径对照

问题类型	未启用视觉辅助 EM	启用视觉辅助 EM	差值
Object position	49.76%	58.65%	+8.89%
Object shape	61.58%	67.33%	+5.75%
Reasoning	62.20%	70.89%	+8.69%
Object existence	91.98%	91.83%	-0.15%

结果显示，视觉辅助组在 Object position、Object shape 和 Reasoning 问题上的 EM 分别高出 **8.89**、**5.75** 和 **8.69** 个百分点。这些问题通常需要识别具体目标，并进一步判断其位置、几何特征或目标间关系；检测框、目标类别等显式视觉证据能够为 Agent 提供更具针对性的推理依据。

对于 Object existence 问题，两组 EM 分别为 91.98% 和 91.83%，基本保持一致。这说明系统对显著目标的存在性判断已经较为稳定，额外视觉证据没有带来明显差异。不同问题类型之间的结果差异表明，视觉辅助的价值并非对所有样本平均生效，而是更多体现在需要目标级定位和关系推理的任务中，这与 VisualTaskPlanner 按问题需求选择辅助路径的设计目标相符。

因此，M³-RS 采用的并非固定调用所有视觉工具的执行方式，而是通过 Planner 识别视觉证据需求，将额外计算优先用于可能受益的问题类型。这种按需组织视觉证据的机制在保持统一问答入口的同时，增强了系统处理位置、形状和推理类问题的能力。由于路径选择与样本内容相关，上述差值反映分层结果之间的统计关联，仍不能等同于同一样本关闭视觉辅助后的严格因果增益。

6.7.2 跨数据集 VQA 迁移对照

表 6-7 跨数据集 VQA 结果对照

数据集	对应 VQA 数据是否参与训练	测试条件	有效预测	EM
VRSBench	是	Validation	35,822	58.83%
XLRS-Bench	否	Zero-shot	3,060	58.99%

VRSBench VQA 在 35,822 条有效预测上的 EM 为 58.83%，XLRS-Bench VQA 在 3,060 条 zero-shot 样本上的 EM 为 58.99%，两者仅相差 0.16 个百分点。XLRS-Bench VQA 未用于 General VQA Agent 训练，并且包含更大幅、更高分辨率的遥感图像，但系统仍保持了与 VRSBench 相近的总体准确率。该结果表明，General VQA Agent 获得的能力没有明显局限于单一数据集的图像分布和问答表达，在数据来源与图像尺度变化后仍表现出较稳定的跨数据集迁移能力。

这一表现也体现了统一多模态基座与领域 Agent 组合的复用价值：面对新的遥感数据源，系统可以在不重新构建完整任务模型的情况下复用既有问答能力，并通过统一的 VisualTaskPlanner 和视觉证据链路适配不同尺度的输入。由于两个数据集的问题类型构成并不完全一致，该对照主要说明总体性能在 zero-shot 条件下保持在相近量级，不表示两套样本具有完全相同的难度。

6.8 推理效率与资源开销

各任务评测分布在 H100 PCIe、RTX 4090、L40S 和 GB10 等不同 GPU 环境。系统在各环境中均采用 Qwen3.5-9B 基座、VisualTaskPlanner—TaskRouter—领域 Agent 架构以及相近的单样本执行方式，因此本节将不同服务器上的结果用于描述系统在实际部署条件下的效率与资源开销量级。对于由多台服务器共同完成的任务，延迟按全部有效计时样本汇总，显存选取较低的一组可信运行记录；对于缺少完整显存监控的任务，则根据相同模型基座和相近执行链路的已有记录进行平均近似。

除 LEVIR-CC 外，表中单样本时间采用运行工件记录的 `inference_seconds`，主要覆盖 Agent 执行、确定性评测与结果工件写入，不包含数据读取、VisualTaskPlanner 规划、模型权重加载及任务排队时间。LEVIR-CC 的时间为 Planner 与 Change Agent 两个独立阶段逐样本耗时之和，属于逻辑端到端时间。

表 6-8 推理效率与资源开销

数据集/任务	时间统计规模	平均时间/s	P50/s	P95/s	近似平均显存/GiB	近似峰值显存/GiB
VRSBench VQA	36,440	7.29	2.88	24.69	26.1	26.4
VRSBench Caption	7,195	10.95	4.75	17.00	26.1	26.4
VRSBench Grounding	16,155	4.19	2.37	9.76	22.0	23.2
VRSBench Counting	5,637	4.44	0.39	18.30	27.6	27.6
XLRS-Bench VQA	3,078	17.02	3.14	75.61	26.1	26.4
XLRS-Bench Caption	634	20.82	21.18	25.10	26.6	27.6
XLRS-Bench Grounding	2,760	23.81	29.67	38.56	26.6	27.6
MME-RealWorld-RS	3,738	10.87	4.76	21.51	26.1	26.4
LEVIR-CC Change Caption	1,332	10.60	10.46	11.30	17.9	18.2

注：时间统计规模由具有合法延迟记录的样本数决定，可能与有效预测数不同，部分具有合法计时的失败样本也纳入延迟统计。除 LEVIR-CC 外，表中时间为 Agent 阶段记录的 `inference_seconds`，不包含 VisualTaskPlanner 规划、数据读取、模型加载和任务排队；LEVIR-CC 时间为 Planner 与 Change Agent 两个独立阶段逐样本耗时之和，并排除各阶段的首条预热样本。显存以对应任务的完整运行记录为优先；同一任务存在多服务器记录时选取较低的一组可信观测，缺少完整记录时根据相同模型基座和相近执行链路的已有结果进行平均近似。因此，表中显存用于描述当前系统的近似运行需求，不作为不同硬件之间的严格比较结果。VRSBench Counting 延迟来自官方 EVAL 计数子集 6,374 问全量运行中的 5,637 条合法计时记录（含 137 条带计时的失败样本），显存为同一运行的现场观测。LEVIR-CC 显存为 Planner 与 Change Agent 两个独立运行阶段的 PyTorch reserved 统计平均值。

从现有时间结果看，系统单样本执行时间随任务类型和输入分辨率呈现明显差异。VRSBench Grounding 的平均执行时间为 4.19 秒，处理链路相对较短；VRSBench Caption 平均为 10.95 秒，高于常规单轮 VQA，体现了较长文本生成带来的额外解码开销。VRSBench Counting 的 P50 仅为 0.39 秒，但平均值为 4.44 秒、P95 达到 18.30 秒，说明多数样本采用较快的处理路径，少量样本触发了耗时更长的专家链路。相比之下，XLRS-Bench 任务受到超高分辨率输入的影响，整体执行时间更长。XLRS Caption 平均时间为 20.82 秒，约为 VRSBench Caption 的 1.9 倍；XLRS Grounding 的 P50 达到 29.67 秒，为当前任务中最高。XLRS VQA 的 P50 仅为 3.14 秒，但 P95 达到 75.61 秒，最大值达到 690.10 秒，呈现明显长尾。带计时的失败样本平均耗时约 391 秒，说明超大图和极端输入不仅增加执行时间，也更容易伴随模型调用异常。上述差异与图像解码、预处理、视

觉证据组织和生成长度等因素相符，但由于实验并非在完全统一的硬件与样本条件下进行，相关分析属于实际部署观察，不作为单一因素的因果结论。

VisualTaskPlanner 采用独立计时。在单样本并发配置下，VRSBench VQA 的 Planner 调用 P50 约为 3.4~5.4 秒；在 L40S 平台的单卡双样本并发配置下，Planner P50 升至约 9.3~10.1 秒，Agent 执行 P50 约为 8.0~9.3 秒，表现出较明显的同卡资源争用。该结果说明，在当前执行方式下，提高卡内样本并发未必能够等比例提高单样本处理效率。由于相关运行对应不同服务器负载和样本切片，这一现象仅作为并发配置的部署观测，仍需在统一硬件和固定样本集上开展控制变量实验。

资源占用方面，现有观测表明，系统在 RTX 4090 48GB 环境中的近似平均运行显存约为 22.0~27.6 GiB，近似峰值约为 23.2~27.6 GiB。其中，VRSBench Grounding 采用较低服务器观测后，平均显存约 22.0 GiB、峰值约 23.2 GiB；XLRS Grounding 平均显存约 26.6 GiB、峰值约 27.6 GiB，体现了超高分辨率图像和视觉辅助链路带来的额外资源开销。对于缺少连续监控的 VQA、Caption 和 MME-RealWorld-RS 任务，本表根据相同 Qwen3.5-9B 基座和相近 Agent 链路的实测结果进行近似。LEVIR-CC 的 Planner 与 Change Agent 分阶段运行，两个阶段平均后的 PyTorch reserved 显存约为 17.9 GiB，近似峰值约为 18.2 GiB。总体来看，当前 BF16 单基座、按任务切换 Adapter 的运行方式可以在 48GB 级 GPU 上完成各项评测，但相关数值主要用于估计系统运行资源量级，不代表目标星载硬件上的最终资源表现。

6.9 失败案例与能力不足

综合各数据集结果，系统在密集目标计数、XLRS 细粒度定位和部分大图空间推理上仍存在明显瓶颈。计数结果可能受到小目标漏检、相邻目标粘连、切片边界、重复目标去除及多专家结果不一致的共同影响；细粒度定位则对局部区域选择、目标尺度、参照物关系理解和坐标回映提出了更高要求。Caption 任务中 BLEU、METEOR 与 CIDEr 之间的分化还表明，模型能够覆盖部分地物词汇和局部短语，但在长描述的判别性表达、细节组合与事实约束方面仍有提升空间。

运行层面，部分样本因模型调用异常或 Schema 校验失败未形成有效预测。这在一定程度反映系统仍然存在一定的不稳定性，这一不稳定性可能来自于模型对于 Schema 的学习效果不强。

6.10 本章小结

本章在 VRSBench、XLRS-Bench、MME-RealWorld-RS 和 LEVIR-CC 上对 M³-RS 进行了多任务评测。现有结果表明，系统在颜色识别、VRSBench 目标定位、遥感图像描述和双时相变化描述方面具有较稳定的能力，并在 XLRS VQA 和 MME-RealWorld-RS 上展现出一定的 zero-shot 迁移能力。Qwen3.5-Flash 外部语义评分从文本语义一致性角度提供了补充观察，但不替代各任务的确定性指标。与此同时，密集目标计数、超高分辨率图像中的细粒度定位以及部分空间关系推理仍是后续优化重点。

第七章 未来工作

尽管 M³-RS 已经完成多模态遥感任务的统一组织与初步验证，但现阶段系统主要在通用 GPU 环境中进行开发和评测，尚未在国产硬件平台上完成端到端部署，也未形成面向受限算力环境的完整压缩方案。考虑到星载与边缘端应用对计算平台自主可控、存储空间、运行功耗和推理时延具有更严格的要求，后续工作将重点围绕国产化硬件平台适配与全链路推理加速展开。其中，国产化适配是系统走向实际部署的基础，模型量化则是在平台迁移基础上进一步降低资源开销的重要手段。

7.1 国产化硬件平台适配

后续工作首先计划面向主流国产 AI 计算平台及其配套软件栈开展适配，使 M³-RS 逐步摆脱对单一软硬件生态的依赖。该工作的目标并非简单替换底层设备名称，而是在保持现有任务规划、确定性路由、领域 Agent 协同、视觉专家调用和评测工件等上层逻辑基本不变的前提下，完成底层计算接口、模型推理引擎、关键算子和资源监控能力的迁移。通过这种分层适配方式，可以尽量缩小平台变化对系统业务逻辑的影响，并为后续在不同国产硬件上的扩展预留统一接口。

M³-RS 当前已经形成较清晰的模块边界。VisualTaskPlanner 负责识别任务及其视觉证据需求，TaskRouter 负责确定性任务分发，各领域 Agent 通过统一模型协议调用多模态基座和视觉专家，设备、精度及部分执行策略则由配置层控制。这种上层工作流与底层推理后端相分离的架构，为跨平台迁移提供了基础。后续适配将主要集中在模型执行与部署层，不需要重新设计任务体系，也不改变统一样本契约、结果工件和评测流程，从而保证迁移前后的功能与实验结果具有可比性。

在计算与模型层，计划优先打通多模态基座模型在国产 AI 加速平台上的加载和推理链路，重点处理设备识别、数据类型、关键算子以及多 LoRA 加载与切换等问题。对于平台已经提供原生支持的算子和模型结构，将优先采用相应的高性能实现；对于暂时缺少直接支持的部分，则考虑通过兼容框架、算子替换或受控的宿主 CPU 回退保证基本功能。在此基础上，进一步适配目标检测、语义分割等视觉专家。针对不同专家模型的结构特点，可分别采用国产框架原生执行、通用中间表示转换或静态图编译等路线，避免以单一迁移方式处理所有组件。现有的图像预处理、几何计算和其他确定性流程原则上继续保留在宿主侧执行，并根据实际运行情况与 AI 加速设备形成协同处理。

在部署与运行层，计划增加面向国产平台的独立配置方案，对设备映射、计算精度、并发方式、内存限制和降级策略进行统一声明；同时补充相应的容器环境、版本清单和资源监控接口，使国产平台部署能够复用现有的运行状态、异常记录和断点恢复机制。平台适配过程中还将继续保持模型与 Adapter 资产校验、运行身份记录和结果路径安全等工程约束，确保平台迁移不会削弱系统现有的可复现性与可审计性。

国产化适配拟按照“基础环境验证—核心模型迁移—视觉专家适配—全系统联调”

的路线逐步推进。第一阶段完成国产软件栈、运行环境和最小推理样例验证，确认多模态基座能够稳定加载并生成结果；第二阶段完成基座模型、多 LoRA 机制及主要视觉专家的迁移，打通从 VisualTaskPlanner 到领域 Agent 的完整执行链；第三阶段在固定代码、模型资产和评测集的条件下开展跨平台对照实验，并根据结果优化算子选择、任务并发和资源调度策略。该路线能够将平台兼容问题与模型精度问题分阶段定位，降低一次性迁移整个系统带来的调试复杂度。

适配结果将从功能、精度、性能和资源四个方面进行验证。功能层面检查任务规划、Agent 路由、专家调用和结果持久化能否完整执行；精度层面在同一模型资产与同一评测集上比较迁移前后的确定性结果和生成式任务指标；性能层面记录平均时延、P95 时延、首 Token 时延和吞吐；资源层面统计模型存储、运行内存、设备显存及功耗。由于目前尚未获得目标国产平台上的完整实测数据，本阶段不预设缺乏实验依据的固定收益或精度阈值，后续将根据同源样本双平台实测结果建立等价性门禁和资源基线。

7.2 全链路量化与推理加速

在完成基本平台适配后，后续还将面向星载和边缘端的资源约束开展全链路量化。已有低比特矩阵计算与量化微调研究表明，大模型权重和部分计算可以采用 8 bit 或 4 bit 表示以降低存储与运行开销，但其精度影响仍需结合具体任务与目标硬件进行校准验证 [19, 20]。量化范围不仅包括 Qwen3.5-9B 多模态基座，也覆盖目标检测、语义分割等视觉专家，从而避免只压缩主模型而由其他组件继续占用大量存储和计算资源。总体上将以当前 BF16 或 FP16 运行结果作为精度基线，逐步探索 INT8、INT4 及混合精度部署形式，比较不同量化配置对模型存储、内存占用、推理时延、吞吐、功耗和任务精度的影响。

考虑到多模态基座与不同视觉专家在结构、算子和数值敏感性方面存在差异，量化工作不会强制所有组件使用相同位宽。对于对低比特表示较为稳定的模块，可优先采用 INT8 或更低比特量化；对于视觉编码、关键注意力计算、输出头等精度敏感部分，则根据校准结果保留较高精度，形成分组件、分层级的混合精度方案。校准数据将从现有任务数据中按既定规则选取，并保持数据来源、样本范围和评测口径可追溯，避免以改变样本纳入规则的方式掩盖量化造成的性能下降。

量化加速将与国产化平台适配联合验证，而不是作为脱离部署环境的独立模型压缩实验。后续将在相同平台、相同输入和相同推理配置下，对不同精度模式进行控制变量比较，并分别考察通用问答、图像描述、目标定位、目标计数和变化理解等任务的精度变化。最终希望形成一组能够根据任务需求和硬件资源进行选择的部署配置，在精度损失可控的前提下降低系统存储与运行开销，为 M³-RS 在国产受限算力平台上的实际部署提供依据。

总体而言，国产化平台适配与全链路量化共同构成 M³-RS 下一阶段的主要工程研究方向。前者解决系统能否在国产软硬件环境中稳定运行的问题，后者进一步解决运行效率与资源占用问题。通过保持上层任务架构稳定、分组件迁移底层执行能力，并以统一评测体系验证精度和资源变化，后续工作将逐步把当前的多任务原型推进为面向星载与边缘端应用的可部署系统。

第八章 结论

本项目面向太空智算环境下遥感任务类型多样、视觉证据需求差异显著以及计算与存储资源受限等问题，研发了多模态遥感智能体系统 M^3 -RS。系统将目标检测与定位、场景分类、变化检测、目标计数和遥感图像描述五类核心能力细化为十个规范任务，并由五类领域 Agent 按照各自的证据需求和输出契约完成处理。在此基础上，项目完成了 VisualTaskPlanner、领域 Agent、共享多模态基座、视觉专家以及统一运行与评测体系的集成，形成了从任务规划、证据组织、模型推理到结果持久化和评测复核的完整技术链路。

本项目的第一项主要创新是提出**面向有限算力约束的多模态遥感领域 Agent 架构**。该架构不依赖为每类任务分别部署一套完整大模型，而是通过任务分解明确不同遥感任务的处理边界，以 Qwen3.5-9B 作为共享多模态基座，并由 VisualTaskPlanner 联合确定任务类别、任务语义和可选的局部视觉证据需求。目标检测、语义分割和变化感知等视觉专家按照任务需要提供候选区域或辅助证据，再由相应领域 Agent 结合全局图像、局部细节和任务契约完成最终推理。通过这种“共享基座、领域分工、专家按需参与”的能力组织方式，系统能够在统一框架内协调坐标、数量、类别、双时相变化和自然语言描述等差异显著的输入输出形式，为有限算力条件下的遥感多任务统一处理提供了新的实现路径。

第二项主要创新是提出**面向 Agent 真实运行链路的工作流对齐微调方法**。与仅使用“图像—问题—答案”样本进行常规多模态微调不同， M^3 -RS 首先按照正式运行契约构造 Agent 输入，由 Agent 执行视觉视图选择、提示组织和可选专家证据调用，再将 Agent 实际提交给 Qwen 的多模态请求作为训练输入，并以统一的 AgentResult 作为监督目标。该方法将任务计划、全局与局部图像、专家证据、正式提示及结构化输出协议共同纳入训练过程，使模型学习的输入组织和输出边界与实际部署流程保持一致，从而缩小训练与运行之间的差异。项目进一步在同一 Qwen3.5-9B 基础权重上分别训练 Planner、General VQA、Caption、Grounding 和 Change 等任务专用 LoRA，使不同任务能力能够独立训练、更新和切换，同时避免重复维护多套基础模型。除此之外，项目还面向星载长期运行中的单粒子翻转风险，设计了结合权重脆弱性分析、Base Model 与 LoRA 分级保护、运行时校验和局部恢复的轻量化容错方案，为后续星载可靠性验证提供了技术基础。

项目在 VRSBench、XLRs-Bench、MME-RealWorld-RS 和 LEVIR-CC 等公开数据集上完成了多任务评测。VRSBench 目标定位任务取得 **71.92%** 的 Acc@0.5 和 **61.70%** 的 Mean IoU；VRSBench VQA 在 35,822 条有效预测上取得 **58.83%** 的 Exact Match；未参与对应训练的 XLRs-Bench VQA 在 zero-shot 条件下取得 **58.99%** 的 Exact Match，表现出一定的跨数据集迁移能力；LEVIR-CC 变化描述任务的 BLEU-4、METEOR 和 ROUGE-L 分别达到 **31.43**、**40.73** 和 **47.04**。VRSBench VQA 的观察性分组结果还显示，

启用视觉辅助的样本在目标位置、目标形状和推理类问题上的 Exact Match 分别高出 **8.89、5.75 和 8.69** 个百分点，说明按任务需求组织目标级视觉证据与系统的设计目标一致，但该结果不等同于同一样本上的严格因果消融。总体而言，M³-RS 验证了通过任务分解、工作流对齐和共享模型能力组织，在单一多模态基座上承接多类异构遥感任务的可行性，为后续面向国产硬件、受限算力平台和星载环境的部署优化奠定了基础。当前结果尚不能证明系统已经具备真实星载平台上的部署效率，相关显存、时延、吞吐和功耗表现仍需在目标硬件上进一步验证。

参考文献

- [1] KUCKREJA K, DANISH M S, NASEER M, et al. GeoChat: Grounded large vision-language model for remote sensing[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 27831–27840. <https://arxiv.org/abs/2311.15826>.
- [2] WANG P, HU H, TONG B, et al. RingMoGPT: A unified remote sensing foundation model for vision, language, and grounded tasks[J]. IEEE Transactions on Geoscience and Remote Sensing, 2025, 63: 1–20. DOI: 10.1109/TGRS.2024.3510833.
- [3] XU W, YU Z, WANG Y, et al. RS-Agent: Automating remote sensing tasks through intelligent agents[EB/OL]. (2024-06-11)[2026-09-04]. <https://arxiv.org/abs/2406.07089>.
- [4] QWEN TEAM. Qwen3.5-9B[EB/OL]. (2026-03-02)[2026-09-04]. <https://huggingface.co/Qwen/Qwen3.5-9B>.
- [5] HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[C]//International Conference on Learning Representations. 2022. <https://arxiv.org/abs/2106.09685>.
- [6] LI X, DING J, ELHOSEINY M. VRSBench: A versatile vision-language benchmark dataset for remote sensing image understanding[C]//Advances in Neural Information Processing Systems. 2024, 37.
- [7] WANG F, WANG H, GUO Z, et al. XLRs-Bench: Could your multimodal LLMs understand extremely large ultra-high-resolution remote sensing imagery?[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2025: 14325–14336.
- [8] ZHANG Y F, ZHANG H, TIAN H, et al. MME-RealWorld: Could your multimodal LLM challenge high-resolution real-world scenarios that are difficult for humans?[C]//International Conference on Learning Representations. 2025. <https://arxiv.org/abs/2408.13257>.
- [9] LIU C, ZHAO R, CHEN H, et al. Remote sensing image change captioning with dual-branch transformers: A new method and a large scale dataset[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1–20. DOI: 10.1109/TGRS.2022.3218921.
- [10] WANG F, CHEN M, LI Y, et al. GeoLLaVA-8K: Scaling remote-sensing multimodal large language models to 8K resolution[C]//Advances in Neural Information Processing Systems. 2025. <https://arxiv.org/abs/2505.21375>.
- [11] LUO J, ZHANG Y, YANG X, et al. When large vision-language model meets large remote sensing imagery: Coarse-to-fine text-guided token pruning[C]//Proceedings of

- the IEEE/CVF International Conference on Computer Vision. 2025: 9206–9217.
- [12] XIA G S, BAI X, DING J, et al. DOTA: A large-scale dataset for object detection in aerial images[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 3974–3983. DOI: 10.1109/CVPR.2018.00418.
- [13] YAN Z, SHI Y, LIAO W, et al. When single event upset meets deep neural networks: Observations, explorations, and remedies[C]//2020 25th Asia and South Pacific Design Automation Conference. 2020: 163–168. DOI: 10.1109/ASP-DAC47756.2020.9045134.
- [14] GUTIÉRREZ-ZABALLA J, BASTERRETXEA K, ECHANOBÉ J. Evaluating single event upsets in deep neural networks for semantic segmentation: An embedded system perspective[J]. Journal of Systems Architecture, 2024, 154: 103242. DOI: 10.1016/j.sysarc.2024.103242.
- [15] AHSAEI S, RAJI M. LOST-ViT: A low overhead soft error tolerance framework for vision transformers via model compression and selective bit-level redundancy[J]. Journal of Systems Architecture, 2026, 170: 103623. DOI: 10.1016/j.sysarc.2025.103623.
- [16] CHEN Y, TAN Z, JAISWAL A K, et al. Bit-flip error resilience in LLMs: A comprehensive analysis and defense framework[C]//Proceedings of EMNLP. 2025: 10414–10424. DOI: 10.18653/v1/2025.emnlp-main.528.
- [17] MA K, AMARNATH C, ISENBERG J, et al. Error resilient transformers: A novel soft error vulnerability guided approach to error checking and suppression[J]. Journal of Electronic Testing, 2026, 42(2): 227. DOI: 10.1007/s10836-026-06227-4.
- [18] FRIAS-DOMÍNGUEZ L, BADIA J M, LEON G, et al. Dependability analysis and hardening of vision transformers against soft errors[J]. The Journal of Supercomputing, 2026, 82(5): 331. DOI: 10.1007/s11227-026-08373-0.
- [19] DETTMERS T, LEWIS M, BELKADA Y, et al. LLM.int8(): 8-bit matrix multiplication for transformers at scale[C]//Advances in Neural Information Processing Systems. 2022, 35: 30318–30332.
- [20] DETTMERS T, PAGNONI A, HOLTZMAN A, et al. QLoRA: Efficient finetuning of quantized LLMs[C]//Advances in Neural Information Processing Systems. 2023, 36: 10088–10115.

附录 A 作品交付与复现说明

A.1 交付材料组成

作品交付包包括技术报告、源代码、模型与 LoRA Adapter、配置文件、运行脚本以及必要的复现说明。源代码以最终提交版本为准，模型文件与该代码版本保持一致。公开数据集不随作品重复分发，数据来源、目录组织和准备方法在随包 README 中说明。

A.2 代码与运行入口

M³-RS 的统一命令行入口为 `python main.py`。运行前需要按照随包 README 安装依赖、准备数据集和模型资产，并通过配置文件声明数据根目录、模型逻辑身份、设备和精度等参数。普通数据加载默认离线，不会在运行过程中隐式下载模型或数据。每次正式运行均生成配置快照、Prompt 快照、事件记录、逐样本状态、预测索引和评测工件，以支持结果复核和断点恢复。

A.3 大容量文件下载信息

模型权重等大容量文件通过百度网盘提供，分享文件名为 M³-RS 童轶。下载链接为 <https://pan.baidu.com/s/1FrXMx5tg2dJrGRxGRWajUw?pwd=2tkk>，提取码为 2tkk。该分享包含与最终提交代码匹配的 Qwen3.5-9B 基础模型、任务 Adapter、SegFormer 及 YOLO OBB 视觉专家资产。

具体资产与配置方式如下：

- **Qwen3.5-9B 基础模型**：逻辑身份为 `Qwen/Qwen3.5-9B:local`。下载后将资产合并至源代码/models/，并在 `configs/local.yaml` 中配置 `model: models/qwen_3.5`。
- **Planner 及领域 Adapter**：包含 Planner、VQA、Caption、Grounding 和 Change 任务 LoRA，位于 `models/adapter/`，按任务在 `configs/local.yaml` 中绑定。
- **视觉专家模型**：包含 YOLO OBB、SegFormer 与 ChangeHead 资产。保持网盘目录结构，使用最终提交版（2026-09-05）配置离线加载，不触发自动下载。

A.4 最小复现流程

最小复现流程包括：安装项目依赖，按照 README 准备基础模型、任务 Adapter 和视觉专家资产，配置本地数据集根目录，使用 `python main.py` 执行单样本或数据集任务，并从对应 run 目录读取预测、确定性评测和报告工件。最终提交包应同时提供一条不依赖在线 Judge 的离线示例命令，以及一条用于复现公开数据集结果的评测命令。

附录 B 模型与 Adapter 资产说明

M³-RS 以 Qwen3.5-9B 作为共享多模态基座，并使用相互独立的 LoRA 承载任务专长。各 Adapter 可以独立训练、更新和加载，基础权重仅需维护一份。视觉专家作为辅助证据来源按需调用，不替代领域 Agent 完成最终语义裁决。

下列 SHA-256 均为最终提交目录中对应权重文件的实测值：

- **VisualTaskPlanner**: visual-planner-final-v1-lr5e-5。

f6c5ab9d71a68f64893fc26fcb524702511abf5cda713bf691a9cf23ffefef1b0

- **General VQA Agent**: general-vqa-agent-lora-full。

08e79e4c316d718c60655fb69d477655042f4ebd04776aa0c5ad73fe510bde62

- **Caption Agent**: caption-agent-lora-v2。

18e11c513a46c93f9988467d7c192e3b2817c7f9e4500c1a1581f9c90d3bc74b

- **Grounding Agent**: grounding-sft-v4-lora-20260829。

591e32f2d68db305dbe5580494871bec4b8fc82548b169538e32638d2c7ef3af

- **Change Agent**: change-agent/final_adapter。

4c2122f59443af6d5ee9ee883615bddb84ea4646fa362ff0fe0c8985f73c54ba

- **ChangeHead**: multi-expert-siamese-change-head-v1。

0973b7b57181f63ac5386a668dc4ba4ab6ae8530a484444a5258ab80e6e6ccca

- **YOLO OBB 专家**: YOLO11m-OBB:DOTA-v2.0:best。

f9db8b4165421f64f8a380a7f1a365de7c94dff98eb5b9606d0e93969ae8eb21

- **SegFormer MiT-B2 iSAID 专家**:

f8e60686ec41160b5cbc494e8a3c1d28a92f7afdd41708c7b77e3d5793908b9a

- **SegFormer MiT-B2 OEM 专家**:

d2141c79b2fc27ea5505db378b48e90e75e5ee06751df1c5b4028ef662fb2fab

最终交付时，每个模型资产应记录逻辑模型身份、版本、文件名称、SHA-256 和适用模块。物理存放路径属于本地部署配置，不作为跨机器模型身份，也不写入可移植结果工件。

附录 C DeepSeek 辅助 Planner 监督字段标注方法

C.1 标注目的与字段范围

公开数据集通常不直接提供 VisualTaskPlanner 所需的任务规划字段。项目采用纯文本 DeepSeek teacher 辅助生成 task、needs_visual_assistance、object_categories 和 count_target 四个字段。DeepSeek 不生成 region_request，也不参与 M³-RS 正式运行时的任务规划或领域 Agent 推理。

C.2 仅问题文本的 Teacher 调用

辅助标注脚本以只读方式读取源数据，只有显式启用 API 调用时才访问外部服务。每个请求只发送原始问题文本，不发送图像、旧 Planner 标签、标准答案、数据来源、文件路径或其他溯源信息。相同问题先进行去重，并使用包含模型、Prompt 版本、问题文本和响应 Schema 的完整请求哈希进行缓存，避免重复调用和不同配置结果混用。

C.3 固定 Prompt 与结构化输出

Teacher Prompt 由完整的 Planner 运行规则、纯文本四字段标注准则和严格 JSON Schema 共同组成。DeepSeek 调用采用 temperature=0、关闭思考模式并要求 JSON 对象输出。返回对象必须满足以下结构：

```
{
  "task": "general_vqa",
  "needs_visual_assistance": true,
  "object_categories": ["ship"],
  "count_target": null
}
```

其中 task 必须属于系统声明的十个规范任务；needs_visual_assistance 必须与 object_categories 是否为空保持一致；计数任务必须具有非空 count_target，非计数任务的 count_target 必须为 null。

C.4 确定性校验与异常隔离

DeepSeek 响应首先经过结构化 Schema 解析，再通过任务集合、字段联动、计数目标、规范类别和当前视觉专家能力等确定性规则校验。脚本还根据问题文本执行任务保护、答案泄漏检查和类别规范化，不把 teacher 输出直接视为最终监督真值。无法解析、

字段冲突或能力不匹配的记录进入隔离清单，不参与训练；标注决策、请求哈希、缓存命中状态和稳定错误码保存在独立审计工件中。经过校验的四字段结果随后与独立获得的图像输入和其他监督信息组装为最终 Planner 训练记录。

附录 D 基于 Qwen3.5-Flash 的外部语义评测方法

D.1 评测定位与适用范围

外部语义评测用于补充 Exact Match 和文本重叠指标对同义表达、合理概括及开放式描述覆盖不足的问题。Judge 结果与确定性指标并列保存，不覆盖或修改 Exact Match、Accuracy、IoU、Counting 误差、BLEU、METEOR、ROUGE-L 和 CIDEr。当前评测覆盖 VQA、Caption、Change Caption 和 Counting；Grounding 涉及图像坐标，纯文本 Judge 无法验证视觉真值，因此无条件跳过。

D.2 输入与任务专用评分准则

Judge 模型使用 Qwen3.5-Flash。每次调用只接收原始问题、一个或多个官方参考答案以及 M³-RS 预测答案，不读取图像，也不使用外部知识。参考答案作为权威的正面证据，但不被假定为对图像全部可见事实的穷尽描述。Judge 需要逐项检查遗漏、无依据补充和事实矛盾，并根据任务使用不同准则：VQA 侧重语义答案正确性；Caption 同时考察参考事实一致性和主要内容覆盖；Change Caption 考察变化对象、变化类型、数量和空间位置；Counting 考察被询问目标和最终数量。

D.3 三轮离散评分与百分制映射

每条有效样本独立调用 Judge 三次，temperature 设置为 0.2，关闭思考模式，每次输出一个 1 至 5 的整数分数和简短理由。结构化输出 Schema 如下：

```
{  
  "score": 5,  
  "concise_rationale": "The prediction is semantically consistent with the references.",  
  "judge_scope": "text_and_structured_evidence_only",  
  "can_verify_visual_truth": false  
}
```

设三次评分分别为 s_1 、 s_2 和 s_3 ，最终外部语义评分为：

$$S = 25 \left(\frac{s_1 + s_2 + s_3}{3} - 1 \right)$$

该方法将三轮离散评分均值线性映射到 0 至 100 分，属于受 G-Eval 启发的多轮评分方法，不声称复现基于 token 概率加权的原始 G-Eval。正式评测对包括 Exact Match 为真的样本在内的全部有效记录执行 Judge，不使用“Exact Match 直接记 100 分”的混合旁路。

D.4 聚合、失败处理与复现配置

外部语义评分按数据来源和任务分别聚合，主要报告成功 Judge 样本的平均分、样本间标准差和 0 至 25、26 至 50、51 至 75、76 至 100 四档分布；平均分不低于 75 的样本比例仅作为辅助统计，不等同于任务 Accuracy。未成功执行的预测、缺少问题或参考答案的记录不进入 Judge 调用，并分别计数；API 失败或结构化解析失败的记录保留失败状态，不自动判错，也不从审计记录中无痕删除。

本次评测使用模型 qwen3.5-flash、Prompt 版本 final-results-geval-inspired-v3、三轮独立评分、temperature=0.2、关闭思考模式、单轮最大输出 512 tokens，并采用 judge_all 口径。最终工件共保存 47,043 条记录，其中 47,037 条成功、6 条失败；逐样本结果、各轮响应和聚合摘要分别保存，便于恢复和复核。模型、Prompt、输入文本、评分次数、温度或 Exact Match 策略变化时，旧结果不得作为同一评测身份继续复用。

附录 E VisualTaskPlan v5 格式

E.1 总体结构

VisualTaskPlan v5 是 VisualTaskPlanner 单次规划调用的结构化输出。该对象采用严格 JSON 格式，不允许出现 Schema 未声明的额外字段。其总体结构如下：

```
{ "version": "visual-task-plan-v5", "task": "grounding", "needs_visual_assistance": true, "object_categories": ["ship"], "count_target": null, "region_request": { "explicit": true, "image_index": 0, "roi_xyxy": [120, 180, 760, 820] }, "reason_codes": ["supervision.manual_roi"] }
```

上述示例仅用于说明字段格式，不表示具体训练样本或模型输出。

E.2 字段定义

表 E-1 VisualTaskPlan v5 字段定义

字段	类型	必填	含义与约束
version	string	是	固定为 visual-task-plan-v5
task	string	是	canonical task，取值范围见表 E-2
needs_visual_assistance	boolean	是	是否需要调用已声明的局部视觉辅助能力
object_categories	array[string]	是	视觉辅助所需的规范物体类别，最多 8 项，不允许重复
count_target	string 或 null	是	计数任务的语义计数目标，最长 80 个字符；非计数任务必须为 null
region_request	object	是	可选关注区域请求，具体字段见表 E-3
reason_codes	array[string]	是	稳定的规划或监督源代码，最多 8 项，每项不超过 64 个字符

表 E-2 canonical task 取值范围

task	含义
counting	常规目标计数
fine_grained_counting	细粒度目标计数
change_caption	双时相变化描述
change_qa	双时相变化问答
grounding	文本目标定位
spatial_relation	空间关系判断
scene_classification	场景分类
general_vqa	通用遥感视觉问答
caption	遥感图像描述
multiple_choice_vqa	多项选择视觉问答

E.3 RegionRequest 格式

region_request 用于表达一个可选的显式关注区域，坐标采用 0 至 999 的整图归一化 xyxy 格式。

表 E-3 RegionRequest 字段定义

字段	类型	必填	含义与约束
explicit	boolean	是	是否提供显式 ROI
image_index	integer 或 null	是	ROI 所属图像在有序图像输入中的零基索引
roi_xyxy	四元整数数组或 null	是	[x0,y0,x1,y1]，每个值位于 0 至 999，且满足 x0<x1、y0<y1

当 explicit=false 时，image_index 与 roi_xyxy 必须同时为 null：
{ “explicit”: false, “image_index”: null, “roi_xyxy”: null }
当 explicit=true 时，image_index 与 roi_xyxy 必须同时存在。image_index 不得超出当前样本的图像数量。ROI 表示大致关注区域，不等同于目标检测框。

E.4 字段联动约束

VisualTaskPlan v5 除字段类型约束外，还要求以下语义联动关系：
当 needs_visual_assistance=true 时，object_categories 必须至少包含一个规范类别。
当 needs_visual_assistance=false 时，object_categories 必须为空数组。

object_categories 中的类别不得重复，不得为空，也不得包含路径形式或控制字符。
当 task 为 counting 或 fine_grained_counting 时，count_target 必须为非空语义目标。
当 task 不是计数任务时，count_target 必须为 null。

count_target 用于描述被计数的对象，不得是纯数字、路径或包含控制字符的字符串。

启用视觉辅助时，object_categories 还必须属于当前任务可调用视觉专家支持的规范类别；不支持的类别不能通过运行时能力校验。

对于计数任务，count_target、object_categories 和 needs_visual_assistance 必须满足当前视觉专家目录定义的一致性约束。

reason_codes 只允许使用稳定的小写字母、数字及 _、.、:、-组成的代码字符串，不用于保存自由文本解释。

这些约束共同保证 Planner 输出能够被确定性 TaskRouter、视觉视图物化流程和各领域 Agent 直接消费。任何字段缺失、类型错误或联动关系不成立的计划均视为无效输出，不通过猜测或默认任务进行修复。